



UTILIZAÇÃO DE REDES NEURAIS ARTIFICIAIS NO ESTUDO DE INSUFICIÊNCIA CARDÍACA

APPLICATION OF ARTIFICIAL NEURAL NETWORKS IN HEART FAILURE STUDIES

UTILIZACIÓN DE REDES NEURONALES ARTIFICIALES EM EL ESTUDIO DE LA INSUFICIENCIA CARDÍACA

Ana Clara David de Moraes¹
Danillo Fernandes dos Santos Padin²
Elaine Inacio Bueno³

DOI: 10.54751/revistafoco.v18n3-051

Received: Feb 10th, 2025

Accepted: Mar 4th, 2025



RESUMO

A ausculta cardíaca é uma prática fundamental para a avaliação da condição do coração, mas requer treinamento específico e experiência dos médicos e de toda a equipe médica envolvida. Para melhorar a precisão e objetividade da avaliação, diversas técnicas computadorizadas podem ser utilizadas. Nesse contexto, este estudo tem como objetivo apresentar uma análise de sons cardíacos com o uso de técnicas de Inteligência Computacional, a fim de auxiliar os médicos na tomada de decisão. Para tal, foi desenvolvida uma metodologia baseada na utilização de Redes Neurais Artificiais (RNAs) para classificar os sons cardíacos em quatro tipos: normal, sopro cardíaco, extra-sístole e artefato cardíaco. Os resultados obtidos indicam um grande potencial das RNAs na classificação de padrões e, portanto, podem ser úteis para melhorar a precisão e objetividade da avaliação da condição do coração.

Palavras-chave: Ausculta-cardíaca; inteligência computacional; redes neurais artificiais; classificação de sons cardíacos.

ABSTRACT

Cardiac auscultation is a fundamental practice for assessing the condition of the heart, but it requires specific training and experience from physicians and the entire medical team involved. To improve the accuracy and objectivity of the assessment, various computerized techniques can be used. In this context, this study aims to present an analysis of heart sounds using Computational Intelligence techniques to assist physicians in decision-making. For this purpose, a methodology was developed based

¹ Graduanda em Engenharia Eletrônica. Instituto Federal de São Paulo (IFSP) - campus São Paulo. Rua Pedro Vicente, 625, Canindé, São Paulo/SP, CEP: 01109-010. E-mail: clara.moraes@aluno.ifsp.edu.br

² Especialista em Controle e Automação. Instituto Federal de São Paulo (IFSP) - campus São Paulo. Rua Pedro Vicente, 625, Canindé, São Paulo/SP, CEP: 01109-010. E-mail: danillopadin@gmail.com

³ Doutora em Ciências. Universidade de São Paulo. Rua Pedro Vicente, 625, Canindé, São Paulo/SP, CEP: 01109-010. E-mail: ebueno@ifsp.edu.br

on the use of Artificial Neural Networks (ANNs) to classify heart sounds into four types: normal, heart murmur, extrasystole, and cardiac artifact. The results obtained indicate a great potential of ANNs in pattern classification and, therefore, they can be useful in improving the accuracy and objectivity of heart condition assessment.

Keywords: Cardiac auscultation; computational intelligence; artificial neural networks; heart sound classification.

RESUMEN

La auscultación cardíaca es una práctica fundamental para evaluar la condición del corazón, pero requiere entrenamiento específico y experiencia por parte de los médicos y de todo el equipo médico involucrado. Para mejorar la precisión y objetividad de la evaluación, se pueden utilizar diversas técnicas computarizadas. En este contexto, este estudio tiene como objetivo presentar un análisis de los sonidos cardíacos utilizando técnicas de Inteligencia Computacional, con el fin de ayudar a los médicos en la toma de decisiones. Para ello, se desarrolló una metodología basada en el uso de Redes Neuronales Artificiales (RNA) para clasificar los sonidos cardíacos en cuatro tipos: normal, soplo cardíaco, extrasístole y artefacto cardíaco. Los resultados obtenidos indican un gran potencial de las RNA en la clasificación de patrones y, por lo tanto, pueden ser útiles para mejorar la precisión y objetividad en la evaluación de la condición del corazón.

Palabras clave: Auscultación cardíaca; inteligencia computacional; redes neuronales artificiales; clasificación de sonidos cardíacos.

1. Introdução

No Brasil, cerca de 300 mil vidas são perdidas a cada ano, sendo que a maioria das causas de morte está relacionada a doenças cardiovasculares, como infarto, acidente vascular cerebral, insuficiência cardíaca ou morte súbita (Simão et al., 2013; Andrade et al., 2013). É importante ressaltar que pelo menos 80% das mortes por complicações cardíacas em todo o mundo são evitáveis (Strong et al., 2005).

A falta de acesso aos serviços de saúde e saneamento, principalmente no que se refere às tecnologias empregadas na detecção e tratamento precoce de problemas que podem levar ao desenvolvimento de cardiopatias, é um dos principais motivos para essa situação, especialmente entre a população mais carente.

A ausculta cardíaca é uma área fundamental da medicina que se insere no contexto da semiologia. Com o passar dos anos, essa linha de pesquisa tem

se tornado cada vez mais relevante, pois possibilita o entendimento dos sons gerados pelos ciclos cardíacos. Através da ausculta cardíaca, é possível realizar diagnósticos precisos e avaliar a intensidade dos distúrbios apresentados pelo paciente. Para realizar o exame, é necessário o uso do estetoscópio, um dispositivo composto por três partes principais: o auscultador, tubos de condução e olivas auriculares. O auscultador pode ter um lado com diafragma ajustável ou dois lados, um com diafragma e outro em formato de sino. Sem diafragma, o auscultador é utilizado para captar sons de frequências mais baixas, enquanto com diafragma é usado para captar sons com frequências mais altas. O auscultador é conectado às olivas auriculares por meio de tubos flexíveis.

Determinar a saúde e situação do coração através da ausculta cardíaca é uma tarefa complexa que exige treinamento e qualificação especializada da equipe médica. No entanto, as ferramentas computacionais podem oferecer soluções mais objetivas e específicas de forma rápida e simples.

A bioinformática (Luscombe et al., 2001) é um campo interdisciplinar que aplica técnicas matemáticas e computacionais na área de bioengenharia. Trata-se de uma área de pesquisa que visa o desenvolvimento e aplicação de métodos computacionais e procedimentos para ampliar a utilização de dados de saúde, incluindo aquisição, armazenamento, organização, visualização e análise das informações disponíveis. Essa tecnologia foi implementada com o objetivo de auxiliar os profissionais da área da saúde na coleta e processamento das informações de forma rápida, detalhada e possibilitando o desenvolvimento de melhorias, sempre visando a preservação da vida. Dentro dessa área de pesquisa, existem diversas metodologias que podem auxiliar nas deduções e tomadas de decisões, sendo uma delas o método de Redes Neurais Artificiais (RNAs). As RNAs são um método computacional inspirado no cérebro humano, que possui a capacidade de aprender através da apresentação de dados contendo informações do processo em análise (Haykin 1999).

1.1 Objetivo

Este trabalho tem como objetivo o desenvolvimento de uma ferramenta automática capaz de analisar sinais sonoros cardíacos com o uso de RNAs. Essa ferramenta terá a finalidade de auxiliar médicos no diagnóstico e na tomada de decisões, realizando a separação entre os sons cardíacos normais e os identificados como patológicos. Para isso, serão utilizadas quatro classes distintas no processo de desenvolvimento da ferramenta: normal, sopro cardíaco, extra-sístole e artefato cardíaco. É importante ressaltar que os três últimos tipos de sons mencionados estão associados a disfunções cardíacas, o que torna o projeto ainda mais relevante para a área médica. Ao separar e identificar esses tipos de sons, a ferramenta permitirá que médicos possam realizar diagnósticos mais precisos e eficazes, além de permitir um acompanhamento mais detalhado e personalizado dos pacientes. Isso trará benefícios não apenas para os pacientes, mas também para a área médica como um todo, uma vez que a análise de sinais sonoros cardíacos pode se tornar mais ágil e eficiente com o uso da tecnologia de RNAs.

2. Referencial Teórico

A bibliografia revisada apresenta trabalhos relacionados à temática deste trabalho, possibilitando assim o estabelecimento de um estudo sobre o estado da arte referente ao emprego de Técnicas de Inteligência Computacional na classificação de sons cardíacos.

O estudo realizado por Chauhan et al. (2008) utilizou técnicas avançadas de processamento de sinal, incluindo a extração de coeficientes cepstrais em frequência mel (MFCC) e modelos ocultos de Markov (HMM - Hidden Markov Models), para classificar os sons cardíacos em três tipos distintos, além do tipo normal. Além disso, para a coleta de dados dos ciclos cardíacos, foi avaliado o uso do domínio do tempo e da transformada de Fourier de curta duração (STFT - Short-Time Fourier Transform, em inglês). Essas técnicas permitiram uma análise mais detalhada dos sinais sonoros cardíacos, contribuindo para o avanço

no diagnóstico e tratamento de doenças cardíacas. Foi utilizada uma base com 1381 registros de sons do ciclo cardíaco coletados por um estetoscópio eletrônico desenvolvido pelos autores. O uso da técnica de propriedade do som em um classificador foi uma contribuição importante para o avanço no diagnóstico e tratamento de doenças cardíacas. As técnicas avançadas de processamento de sinal utilizadas permitiram a classificação de sons cardíacos em tipos distintos, o que possibilitou uma análise mais detalhada dos sinais sonoros e um diagnóstico mais preciso e efetivo dessas doenças.

A pesquisa conduzida por Zhong et al. (2013) propôs o reconhecimento de sopros cardíacos utilizando o modelo matemático HMM. Para avaliar a eficácia da proposta, foi utilizada uma base de dados composta por 600 áudios do ciclo cardíaco, contendo amostras de sinais normais e cinco tipos diferentes de sopros. A fim de classificar o sinal MFCC, que foi extraído como atributos do áudio foram testados quatro modelos de HMM. O uso dessas técnicas avançadas de processamento de sinal permitiu aos pesquisadores uma análise mais precisa e automatizada dos sons cardíacos. Esse método foi capaz de reconhecer o sopro de forma eficiente próximo 94,2% de assertividade e possibilitou a identificação não apenas da presença de sopro cardíaco, mas também o tipo de sopro presente. Entretanto, sua análise se baseia em apenas uma única característica do áudio (MFCC) e não faz uso de técnicas de aprendizado de máquina para a classificação dos áudios.

De maneira similar, Jimenez et al. (2014) obtiveram resultados satisfatórios ao utilizar características derivadas do MFCC, mas não efetuaram a leitura de arquivos de áudio, uma vez que já possuíam uma base de dados pronta com sinais de MFCC coletados a partir de exames de Fonocardiografia. Além disso, outros tipos de características do áudio, como escalas, sinais e medidas, não foram explorados, e os atributos também não foram analisados por um software específico ou aplicados a um algoritmo de aprendizado de máquina. O objetivo principal é detectar a presença de sopros cardíacos em sinais de ausculta cardíaca. Para alcançar esse objetivo, utilizou-se quatro características extraídas do sinal MFCC e foram aplicados métodos de pré-processamento para coletar e segmentar os dados, além de técnicas de decomposição do sinal.

Embora a pesquisa não tenha explorado outros tipos de características do áudio, os resultados obtidos sugerem que a abordagem adotada foi efetiva na detecção de sopros cardíacos em sinais de ausculta cardíaca. No entanto, é importante destacar que outras abordagens podem ser exploradas para aprimorar a detecção de sopros cardíacos em sinais de ausculta cardíaca, especialmente considerando a evolução contínua da tecnologia e dos algoritmos de aprendizado de máquina.

O trabalho realizado por Pereira e Silveira (2015) propôs o uso de um sistema fuzzy para avaliar o risco de um paciente sofrer um ataque cardíaco com base em fatores de risco estabelecidos pelo National Cholesterol Education Program. O sistema considerou como entradas a idade do paciente, hipertensão, diabetes e outros fatores relevantes. O método de inferência utilizado foi o Mamdani e a defuzzificação foi realizada por meio do método do Centro de Gravidade. Os resultados das simulações mostraram o grau de pertinência de um paciente a um determinado quadro clínico, em relação aos conjuntos fuzzy associados ao risco de ataque cardíaco e o modelo foi capaz de compreender as hipóteses contraditórias que envolvem o fenômeno, gerando respostas coerentes com as informações presentes na literatura.

No estudo conduzido por Santos (2020), uma abordagem baseada em máquina de Vetores de Suporte, conhecida como Support Vector Machine (SVM), foi utilizada para prever óbitos decorrentes de ataques cardíacos, utilizando o conjunto de dados públicos denominado "Echocardiogram Data Set", que contém 140 amostras. A classificação das amostras foi realizada por meio da ferramenta WEKA, resultando em uma acurácia de 95%. Esses resultados indicam que a abordagem proposta por Santos pode ser uma ferramenta valiosa para ajudar os médicos a prever o risco de óbito em pacientes com problemas cardíacos e tomar decisões mais assertivas sobre o tratamento apropriado. No entanto, é importante ressaltar que são necessárias mais investigações para avaliar a generalização e a aplicabilidade da abordagem em outros conjuntos de dados e contextos clínicos.

A proposta deste trabalho consiste em utilizar técnicas de processamento de sinais e aprendizado de máquina para identificar e classificar diferentes tipos

de sinais cardíacos. Para isso, serão exploradas diversas características sonoras dos sinais, como a presença de sopros, extra-sístoles e artefatos cardíacos. A partir da extração dessas características, serão desenvolvidos algoritmos de aprendizado de máquina capazes de classificar automaticamente os sinais em quatro categorias: coração normal, com sopro, extra-sístole ou artefato cardíaco.

Ao contrário de estudos anteriores, este trabalho pretende desenvolver uma interface gráfica amigável e prática para apresentar os resultados da classificação de forma clara e eficiente. Isso permitirá que médicos e profissionais de saúde possam avaliar rapidamente o diagnóstico dos pacientes e tomar decisões mais assertivas, reduzindo o tempo de espera e melhorando a qualidade do atendimento.

Além disso, espera-se que os resultados deste trabalho possam contribuir para o desenvolvimento de novas ferramentas de diagnóstico não invasivas e mais precisas para problemas cardíacos. A utilização de técnicas de aprendizado de máquina para análise de sinais sonoros pode trazer avanços significativos para a área de saúde, oferecendo novas opções de diagnóstico e tratamento para pacientes em todo o mundo.

3. Metodologia

Neste trabalho, foram utilizadas as seguintes metodologias: RNAs e repositório de dados de doenças cardíacas, cuja base de dados foram utilizadas no treinamento das RNAs para a classificação de doenças cardíacas.

3.1 Redes Neurais Artificiais (RNAs)

As Redes Neurais Artificiais podem ser definidas como sistemas paralelos compostos por unidades de processamento simples, dispostas em camadas e altamente interligadas, inspiradas no cérebro humano (Haykin 1999). O aprendizado de uma RNA é realizado a partir de um algoritmo, conhecido como algoritmo de aprendizagem, onde os pesos sinápticos são atualizados com o

propósito de alcançar o objetivo desejado. As formas em que os neurônios das RNAs são organizados estão intimamente associadas ao algoritmo de aprendizado utilizado no treinamento das redes. Geralmente, podemos identificar três tipos de arquiteturas de RNAs (Haykin 1999): redes com propagação para frente de uma camada: compostas por uma camada de entrada e outra de saída; redes com propagação para frente de múltiplas camadas: compostas por uma camada de entrada, camadas ocultas e uma camada de saída; e redes recorrentes: contêm realimentação das saídas para as entradas. O principal objetivo do treinamento de uma RNA é fazer com que a aplicação de um conjunto de entradas produza um conjunto de saídas desejadas ou no mínimo um conjunto de saídas consistentes. Cada conjunto de entrada ou saída é denominado vetor. O treinamento é realizado pela aplicação sequencial dos vetores de entrada (e em alguns casos também os de saída), enquanto os pesos da rede são ajustados de acordo com um procedimento de treinamento pré-determinado. Durante o treinamento, os pesos da rede gradualmente convergem para determinados valores, de tal maneira que a aplicação dos vetores de entrada produza as saídas necessárias. Os procedimentos de treinamento das RNA's podem ser classificados em duas classes: supervisionado e não supervisionado. O treinamento supervisionado, utilizado no desenvolvimento deste trabalho, necessita de um vetor de entrada e um vetor de saída, conhecido como vetor alvo. Esses dois vetores são então utilizados para o treinamento da RNA. O procedimento de treinamento funciona da seguinte maneira: o vetor de entrada é aplicado, a saída da rede é calculada e comparada com o correspondente vetor alvo. O erro encontrado é então realimentado através da rede e os pesos são atualizados de acordo com um algoritmo com o propósito de minimizar este erro. Este processo de treinamento é repetido até que o erro para os vetores de treinamento alcance valores pré-determinados. Neste trabalho, utilizou-se a arquitetura MLP (Redes de Camadas Múltiplas), treinada pelo algoritmo de retropropagação (Backpropagation).

3.2 Doenças Cardíacas

Para a realização deste trabalho, utilizou-se quatro tipos de sons cardíacos: normal, sopro cardíaco, extra-sístole e artefato cardíaco. O sopro cardíaco caracteriza-se como um distúrbio no fechamento das válvulas, quando ocorre fluxo normal através de uma área pequena ou irregular, permitindo um retorno do sangue (Martins et al., 2008). A intensidade de um sopro é diretamente proporcional à velocidade do fluxo sanguíneo, que por sua vez depende da pressão. A extra-sístole ventricular (ESV) é um tipo de arritmia cujos batimentos prematuros são de origem ventricular, sendo muito comum no ser humano, indiferente de ter ou não uma disfunção cardíaca (Hinkle et al., 1969). Os artefatos podem ser definidos como anormalidades, e são medidas de potenciais na superfície do corpo, não estando relacionadas à atividade elétrica do coração (Ortega, 2005).

3.3 Repositório de Dados

Nesse trabalho, utilizou-se um repositório de dados composto por um total de cento e vinte e quatro sons de em média dez segundos cada um, divididos em quatro classes: 31 sons cardíacos do tipo normal, 34 sons do tipo sopro cardíaco, 19 sons do tipo extra-sístole e 40 sons cardíacos do tipo artefato. Esse repositório está disponível no site (BENTLEY et. al., 2024), que tem como proposta desafios de classificação de sons cardíacos. Esses dados foram obtidos a partir de um ensaio clínico em hospitais, utilizando o estetoscópio DigiScope digital.

4. Resultados e Discussões

Para a implementação da metodologia proposta neste trabalho, utilizou-se a toolbox de Redes Neurais Artificiais do Matlab. No treinamento das RNAs foi utilizado o algoritmo de retropropagação, com a seguinte arquitetura: uma camada de entrada, uma camada oculta e uma camada de saída. Na camada

de entrada foi utilizada a função linear; na camada oculta, a tangente hiperbólica e na camada de saída, a função linear. Foram utilizados 10 neurônios na camada oculta. Utilizou-se ainda o critério de Parada Antecipada para interromper o treinamento, onde a base de dados foi dividida da seguinte forma: 60% para treinamento, 20% para validação e 20% testes. Na Figura 1 é apresentada a matriz de confusão na classificação de 1 som cardíaco do tipo artefato + 1 do tipo normal, e a Tabela 1 apresenta uma síntese dos resultados obtidos até o presente momento.

Figura 1. Classificação de sons cardíacos (1 artefato e 1 normal)




Tabela 1. Análise dos resultados obtidos

Modelo	Som cardíaco	Quantidade de sinais	% (acerto de cada sinal)	% (acerto total)
1	Artefato	2	98,7	73,7
	Normal	2	48,5	
2	Artefato	3	98,7	72,1
	Normal	3	45,5	
3	Artefato	4	93,2	63,4
	Normal	4	33,5	
4	Artefato	1	0,8	33,1
	Normal	1	81,5	
	Extra-sístole	1	16,8	
5	Artefato	2	97,8	51,7
	Normal	2	14,5	
	Extra-sístole	2	42,9	
6	Artefato	3	97,5	48,6
	Normal	3	11,6	

Modelo	Som cardíaco	Quantidade de sinais	% (acerto de cada sinal)	% (acerto total)
7	Extra-sístole	3	36,7	43,0
	Artefato	4	88,7	
	Normal	4	6,8	
	Extra-sístole	4	33,6	

Fonte: Próprio autor

Através da análise da tabela acima, verifica-se que o melhor modelo para classificação de sons cardíacos, foi o modelo 1, cuja porcentagem de acerto da rede foi de 73,7%.

Com o objetivo de otimizar os resultados obtidos, foram realizados treinamentos de novas RNAs, utilizando outros arquivos de sons disponíveis no repositório de dados de sons cardíacos (vide seção Repositório de dados). Na tabela 2 é apresentado um resumo dos resultados obtidos.

Tabela 2. Análise dos resultados obtidos

Modelo	Som cardíaco	Quantidade de sinais	% (acerto de cada sinal)	% (acerto total)
8	Artefato	1	99,2	71,9
	Normal	1	44,7	
9	Artefato	1	98,6	90,1
	Normal	1	81,7	

Fonte: Próprio autor

Através da análise da tabela acima, verifica-se que o melhor modelo para classificação de sons cardíacos, foi o modelo 9, cuja porcentagem de acerto da rede foi de 90,1%. Nota-se que ao utilizarmos diferentes arquivos de sons no treinamento das RNAs, houve uma melhora na classificação dos sons cardíacos, dessa forma, esses arquivos de sons que serão utilizados no treinamento das redes.

5. Considerações Finais

Este trabalho tem como objetivo principal explorar o potencial das Redes Neurais Artificiais (RNAs) na classificação de sons de ausculta cardíaca em quatro tipos: normal, sopro, extra-sístole e artefato. A utilização de RNAs na classificação desses sons pode ser uma ferramenta importante para apoiar os

profissionais de saúde no diagnóstico de disfunções cardíacas, uma vez que essa é uma tarefa complexa e desafiadora. Os resultados obtidos mostraram que as RNAs são capazes de classificar os sons cardíacos em suas respectivas categorias. No entanto, ainda há espaço para melhorias, especialmente na identificação dos tipos de sons mais sutis, como as extra-sístoles, e na redução dos falsos negativos. Com isso, pretende-se continuar a pesquisa nesta área, realizando testes com outras combinações de sons cardíacos e aumentando o número de sinais lidos pela rede, com o objetivo de aprimorar a precisão da classificação. Ademais, a utilização de RNAs na classificação de sons cardíacos é uma área de grande interesse para a medicina e pode ser aplicada em diversas situações clínicas, desde triagem em consultórios médicos até monitoramento em tempo real em hospitais. Por isso, os resultados obtidos neste trabalho podem contribuir para o desenvolvimento de novas tecnologias que auxiliem no diagnóstico e tratamento de doenças cardíacas, promovendo uma melhoria na qualidade de vida dos pacientes

REFERÊNCIAS

- ANDRADE, J. et al. **Sociedade Brasileira de Cardiologia-Carta do Rio de Janeiro-III Brasil Prevent/I América Latina Prevent**. Arquivos brasileiros de cardiologia, 2013.
- BENTLEY, P. et. al. **Classifying heart sounds Challenge**. Disponível em: <https://istethoscope.peterjbentley.com/heartchallenge/index.html#testprocedure>. Acesso em: 22 de julho de 2024.
- CHAUHAN, S. et al. Acomputer-aided MFCC based HMM system for automatic auscultation. **Computers in Biology and Medicine**, v. 38, p. 221-233, feb. 2008. Disponível em: <<https://goo.gl/kVTDxL>>. Acesso em: 23 fevereiro 2023.
- HAYKIN, S. **Neural Networks – A comprehensive Foundation**. Prentice Hall, 1999.
- HINKLE, L. **The frequency of asymptomatic disturbances of cardiac rhythm and conduction in middle-aged men**. The american jornal of Cardiology, 1969.
- JIMENEZ, J. A. *et al.* Heart murmur detection using ensemble empirical mode decomposition and derivations of the mel-frequency cepstral coefficients on 4-area phonocardiographic signals. **Computing in Cardiology**, v. 41, p. 493-496,

2014. Disponível em: <<http://www.cinc.org/archives/2014/pdf/0493.pdf>>. Acesso em: 25 fevereiro 2023.

LUSCOMBE, N. et al. **What is bioinformatics. An introduction and overview**. Yearbook of Medical Informatics, 2001.

MARTINS, P. et al. **O sopro num coração normal**. Revista Portuguesa de Cardiologia, 2008.

ORTEGA-CARNICER, J. **Tremor-related artefact mimicking ventricular tachycardia**. Resuscitation, 2005.

PEREIRA, N. K. M., Silveira, G. P. “**Aplicação da lógica fuzzy no estudo do risco de ataque cardíaco**”. Proceeding Series of the Brazilian Society of Computational and Applied Mathematics, 2015.

SANTOS, J. P. M. S. “**Metodologia baseada em máquina de vetores de suporte para previsão de óbitos por ataque cardíaco**”. UNIFAP, 2020.

SIMÃO, A. et al. **I Diretriz brasileira de prevenção cardiovascular**. Arquivos brasileiros de cardiologia, 2013.

TRONG, K. et al. **Preventing chronic diseases: how many lives can we save?** The Lancet, 2005.

ZHONG, L. et al. Heart murmur recognition based on hidden markov model. **Journal of Signal and Information Processing**, v. 4, p. 140-144, maio 2013. Disponível em: <<https://goo.gl/jo7BBk>>. Acesso em: 24 fevereiro 2023.