



**UFAM**

**UNIVERSIDADE FEDERAL DO AMAZONAS - UFAM  
FACULDADE DE TECNOLOGIA  
DEPARTAMENTO DE ELETRÔNICA E COMPUTAÇÃO  
ENGENHARIA ELÉTRICA - TELECOMUNICAÇÕES**

**DIEGO GIOVANNI DE ALCÂNTARA VIEIRA**

**APRIMORAMENTO DA DETECÇÃO DO COMPLEXO QRS EM EXAMES DE  
ELETROCARDIOGRAMA NA PRESENÇA DE ANOMALIAS**

**MANAUS  
2024**

**DIEGO GIOVANNI DE ALCÂNTARA VIEIRA**

**APRIMORAMENTO DA DETECÇÃO DO COMPLEXO QRS EM EXAMES DE  
ELETROCARDIOGRAMA NA PRESENÇA DE ANOMALIAS**

Pesquisa desenvolvida durante a disciplina FTL056 – Projeto Final de Curso e apresentada à banca avaliadora do curso de Engenharia Elétrica – Telecomunicações da Universidade Federal do Amazonas como requisito parcial para a obtenção do grau de bacharel em Engenharia Elétrica - Telecomunicações.

**Orientadora: Prof<sup>a</sup>. Dr<sup>a</sup>. Marly Guimarães Fernandes Costa**  
**Coorientador: Prof. Dr. Cícero Ferreira Fernandes Costa Filho**

**MANAUS**  
**2024**

## Ficha Catalográfica

Ficha catalográfica elaborada automaticamente de acordo com os dados fornecidos pelo(a) autor(a).

V658a      Vieira, Diego Giovanni de Alcântara  
              Aprimoramento da detecção do complexo QRS em exames de  
              eletrocardiograma na presença de anomalias / Diego Giovanni de  
              Alcântara Vieira . 2024  
              56 f.: il. color; 31 cm.

              Orientador: Marly Guimarães Fernandes Costa  
              Coorientador: Cícero Ferreira Fernandes Costa Filho  
              TCC de Graduação (Engenharia Elétrica - Telecomunicações) -  
              Universidade Federal do Amazonas.

              1. Eletrocardiograma. 2. Complexo QRS. 3. Anomalias. 4.  
              Detecção. 5. Redes neurais convolucionais. I. Costa, Marly  
              Guimarães Fernandes. II. Universidade Federal do Amazonas III.  
              Título

**Diego Giovanni de Alcântara Vieira**

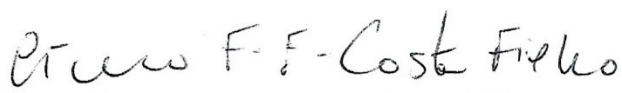
**Aprimoramento da Detecção do Complexo QRS em Exames de  
Eletrocardiograma na Presença de Arritmias**

Monografia apresenta à Coordenação do  
Curso de Engenharia Elétrica –  
Telecomunicações da Faculdade de  
Tecnologia da Universidade Federal do  
Amazonas como requisito parcial para a  
obtenção do grau de bacharel em  
Engenharia Elétrica – Telecomunicações.


Aprovado em 01 de abril de 2024



Prof. Dra. Marly Guimarães Fernandes Costa  
Presidente/UFAM



Prof. Dr. Cícero Ferreira Fernandes Costa Filho  
Membro/UFAM



MSc. Mateus de Paula da Silva  
Membro Externo

## AGRADECIMENTOS

Agradeço aos meus orientadores, Prof<sup>ª</sup>. Dr<sup>ª</sup>. Marly Guimarães Fernandes Costa e Prof. Dr. Cícero Ferreira Fernandes Costa Filho pela orientação durante a execução deste projeto, e pelas aulas ministradas durante as disciplinas de Processamento Digital de Imagens, Engenharia Biomédica, bem como o acompanhamento durante a primeira turma da *task* Inteligência Artificial e Aplicações em Saúde (ICTSr-IA&HC) do Projeto Super (WP3-CETELI-ICT-Sr) no ano de 2020, experiência que mudou minha carreira profissional.

Agradeço a memória de meu pai, José Raimundo Reis Vieira, falecido em 2021 em decorrência da pandemia de Covid-19. O esforço que ele, em conjunto com minha mãe, Sandra Maria de Alcântara Vieira, fizeram ao longo de minha vida, com muito esforço e luta para que eu sempre tivesse as melhores condições possíveis para me dedicar aos estudos, e que nada me faltasse, é algo inestimável em minha vida. Eles me deram a vida e me tornaram a pessoa que eu sou. Agradeço também aos meus irmãos, Jussandro de Alcântara Vieira, e Giselle de Alcântara Vieira, que também equilibram os pratos de nossa dinâmica familiar para que possamos juntos sempre evoluirmos como pessoas e família, nos ajudando mutuamente em razão de nossa mãe.

Agradeço a Universidade Federal do Amazonas, a Faculdade de Tecnologia e ao Centro de Tecnologia de Eletrônica e da Informação – CETELI, por todas as horas que vivi nos ambientes, seja em aulas, laboratórios, projetos de pesquisa, monitorias, convivência social, durante toda a minha trajetória acadêmica, bem como todos os educadores que tiveram presentes durante a minha trajetória e contribuíram em minha formação acadêmica e profissional.

Esta pesquisa, realizada no âmbito do projeto Samsung-UFAM de Ensino e Pesquisa (SUPER), de acordo com o Artigo 39 do Decreto nº 10.521/2020, foi financiada pela Samsung Eletrônica da Amazônia LTDA, nos termos da Lei Federal nº 8.387/1991, através do convênio 001/2020 firmado com a UFAM e FAEPI, Brasil.

## **RESUMO**

As doenças cardiovasculares são um conjunto de anomalias do coração e dos vasos sanguíneos, incluindo doenças coronarianas, cardiovasculares, arritmias cardíacas e outras condições. Segundo a Organização Mundial da Saúde (OMS), quatro a cada cinco mortes por doenças cardiovasculares ocorrem prematuramente em pessoas abaixo dos 70 anos de idade. O diagnóstico dessas doenças normalmente é feito através do exame de eletrocardiograma (ECG), que registra a atividade elétrica do coração. O ECG padrão possui 12 derivações, cada uma representando graficamente as diferenças de potencial em diferentes partes do corpo, permitindo a análise do ciclo cardíaco e a identificação de anomalias. As formas de onda mais importantes no ECG são P, Q, R, S e T, sendo o conjunto delas denominado complexo QRS, que representa a despolarização ventricular. Cinco anomalias características do complexo QRS denotam patologias cardíacas. Esta pesquisa baseou-se na detecção do complexo QRS em ECGs com 12 derivações, utilizando redes neurais convolucionais, aprimorando o trabalho anterior considerando a presença de anomalias cardíacas.

**Palavras-chave:** doenças cardiovasculares, eletrocardiograma, complexo QRS, anomalias, detecção, redes neurais convolucionais.

## **ABSTRACT**

Cardiovascular diseases are a set of disorders of the heart and blood vessels, including coronary artery disease, cardiovascular disease, cardiac arrests, and other conditions. According to the World Health Organization, four out of five deaths from cardiovascular diseases occur prematurely in people under 70 years of age. The diagnosis of these diseases is usually made through an electrocardiogram (ECG), which records the heart's electrical activity. The standard ECGs has 12 leads, each representing graphically the differences in potential in different parts of the body, allowing for the analysis of the cardiac cycle and the identification of anomalies. The most important waveforms in the ECG are, P, Q, R, S and T, with the set of them being called the QRS complex, representing ventricular depolarization. Five characteristic anomalies of the QRS complex denote cardiac pathologies. This research was based on the detection of the QRS complex in 12-lead ECGs using convolutional neural networks, improving on previous work by considering the presence of these anomalies.

**Keywords:** cardiovascular diseases, electrocardiogram, QRS complex, anomalies, detection, neural networks.

## LISTA DE FIGURAS

Figura 1 - Estruturas do coração. Adaptado de (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018).....	19
Figura 2 - Formas de onda básica do ECG em um ciclo cardíaco. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018).....	21
Figura 3 - Elementos do eletrocardiograma. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018).....	22
Figura 4 - Formas análogas do complexo QRS. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018).....	23
Figura 5 - Disposição dos eletrodos no eletrocardiograma padrão de 12 derivações. (SAINI; GUPTA, 2022).....	24
Figura 6 - Triângulo de Eindhoven.....	25
Figura 7 - Anomalias de bloqueio do ramo direito. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018).....	27
Figura 8 - Anomalia de bloqueio do ramo esquerdo. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018).....	27
Figura 9 - Anomalias do infarto do miocárdio – bloqueio intraventricular. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018).....	28
Figura 10 - Padrões do QRS relacionados à síndrome WPW. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018).....	28
Figura 11 - Diagrama esquemático de um neurônio ou modelo <i>perceptron</i> .....	29
Figura 12 - <i>Perceptron</i> multicamadas. Adaptado de (SILVA, 2023).....	30
Figura 13 - Diagrama em blocos apresentando as etapas para aprimoramento da detecção do complexo QRS.....	33
Figura 14 – Identificação das anomalias registradas nos arquivos ATR.....	36
Figura 15 - Filtragem dos picos V.....	37
Figura 16 - Aspecto visual do <i>SignalLabeler</i> .....	38
Figura 17 - Exemplos de complexos quatro complexos QRS normais e um anômalo anotados.....	39
Figura 18 - Algoritmo que relaciona amostras e anotações.....	40
Figura 19 - Algoritmo de normalização dos intervalos.....	41
Figura 20 – (a) Sinal de eletrocardiograma com os complexos QRS visíveis (b) sinal normalizado. correspondente.....	41
Figura 21 - Algoritmo de transformação de intervalos anotados para padrão-ouro.....	42
Figura 22 - Arquitetura da CNN 1. (SILVA, 2023).....	43
Figura 23 - Arquitetura da CNN 2. (SILVA, 2023).....	43
Figura 24 - Arquitetura da CNN 3. (SILVA, 2023).....	44
Figura 25 - (a) Gráfico de convergência de precisão e (b) perda em função do número de épocas, para a primeira derivação na arquitetura CNN1.....	47



## LISTA DE TABELAS

Tabela 1 - Formas de onda do ECG e sua relação com o ciclo cardíaco.....	20
Tabela 2 - Relações de patologias cardíacas presentes na base de dados INCART.....	35
Tabela 3 - Resultados das métricas obtidos por Silva (2023) para as arquiteturas propostas pelo experimento base sem aumento de dados.....	50
Tabela 4 - Resultados das métricas obtidas na execução deste trabalho para as arquiteturas proposta após a realização do aumento de dados.....	51
Tabela 5 - Diferenças percentuais entre as métricas do experimento com aumento de dados relacionando antes e após a etapa de pós-processamento.....	52
Tabela 6 - Comparativo entre as arquiteturas com melhor desempenho considerando a aplicação de aumento de dados no trabalho atual com o experimento base proposto por Silva, (2023).....	53

## LISTA DE SIGLAS

ECG – Eletrocardiograma de 12 derivações

CNN – Rede Neural Convolucional (do inglês, *Convolutional Neural Network*)

OMS – Organização Mundial da Saúde

AE – Átrio Esquerdo

AD – Átrio Direito

VE – Ventrículo Esquerdo

VD – Ventrículo Direito

aVR – Derivação unipolar aumentada do braço direito

aVL – Derivação unipolar aumentada do braço esquerdo

aVF – Derivação unipolar aumentada da perna esquerda.

LBBB – Bloqueio do Ramo Esquerdo (do inglês, *left bundle Branch block*)

RBBB – Bloqueio do Ramo Direito (do inglês, *right bundle Branch block*)

## SUMÁRIO

AGRADECIMENTOS.....	5
RESUMO.....	6
ABSTRACT.....	7
LISTA DE FIGURAS.....	8
LISTA DE TABELAS.....	9
LISTA DE SIGLAS.....	10
SUMÁRIO.....	11
INTRODUÇÃO.....	13
1.1    Objetivo Geral.....	14
1.2    Objetivos específicos.....	14
1.3    Organização do trabalho.....	14
2    Revisão Bibliográfica.....	16
2.1    Detecção do complexo QRS em eletrocardiogramas com 12 derivações utilizando redes neurais convolucionais (SILVA, 2023).....	16
2.2 <i>A detailed guide for quantification of myocardial scar with the Selvester QRS score in the presence of electrocardiogram confounders</i> (LORING et al., 2011).....	17
3    Referencial Teórico.....	18
3.1    Eletrocardiograma.....	18
3.2    Eletrofisiologia cardíaca.....	18
3.3    Formas de onda básicas do Eletrocardiograma.....	19
3.4    Complexo QRS.....	22
3.5    Derivações do eletrocardiograma.....	23
3.6    Anomalias do Complexo QRS.....	25
3.7    Fundamentos das Redes Neurais Artificiais (RNA).....	28
3.8    Redes Neurais Multicamadas.....	29
3.9    Funções de Ativação.....	30
3.10    Aprendizado supervisionado e treinamento da rede neural.....	31
3.11    Redes Neurais Convolucionais.....	31
4    Materiais e Métodos.....	33
4.1    Materiais.....	34
4.1.2    Base de Dados.....	34
4.1.2    Definição do ambiente de desenvolvimento.....	35

4.2 Métodos.....	36
4.2.1 Algoritmo de marcação das anomalias.....	36
4.2.2 Anotação dos complexos QRS para aumento de dados.....	37
4.2.3 Processos pós-anotação para aumento de dados.....	39
4.2.4 Normalização dos intervalos.....	40
4.2.5 Transformação dos novos dados anotados em imagem padrão-ouro.....	42
4.2.6 Definição das Arquiteturas de Redes Neurais Convolucionais.....	42
4.2.7 Execução dos treinamentos.....	44
4.2.8 Pós-Processamento.....	44
4.2.9 Métricas de Avaliação de Desempenho.....	44
5 Resultados e Discussões.....	46
5.1 Aumento de Dados.....	46
5.2 Convergência da Rede Neural Convolucional.....	46
5.3 Análise dos Resultados.....	48
6 CONCLUSÕES.....	54
6.1 Trabalhos Futuros.....	55
Referências Bibliográficas.....	56

## INTRODUÇÃO

Doenças cardiovasculares são um conjunto de desordens do coração e dos vasos sanguíneos que incluem doenças coronarianas, cardiovasculares, arritmias cardíacas e outras condições. Estima-se que em 2019 17.9 milhões de pessoas morreram de doenças cardiovasculares, CVD (do inglês *cardiovascular diseases*), o que representa 32% das mortes globais, segundo dados da Organização Mundial da Saúde (OMS) (WHO, 2021).

O diagnóstico de muitas doenças cardiovasculares é realizado através da análise clínica de um exame denominado de eletrocardiograma (ECG). Tal procedimento consiste na leitura dos sinais bioelétricos relacionados à atividade cardíaca do paciente em diferentes partes do corpo através de um eletrocardiógrafo. Cada diferença de potencial de determinados pontos do corpo da pessoa em relação a terra é chamada de derivação. Existem 12 derivações em um ECG padrão, utilizado como base para os dados deste presente trabalho. Cada uma delas representa graficamente as diferenças de potencial mencionadas acima, e elas se comportam em determinados padrões que permitem analisar e visualizar comportamentos comuns ao ciclo cardíaco, bem como anomalias relacionadas a doenças cardiovasculares.

A representação dos sinais em 12 derivações de um ECG padrão compreendem em formas de onda que podem ser nomeadas como P, Q, R, S e T. Essas ondas se repetem continuamente em sequência ao longo do ciclo cardíaco, enquanto o conjunto das ondas intermediárias é denominado complexo QRS, e representa a despolarização ventricular, processo que indica a ejeção de sangue nas artérias. Há ao todo na literatura médica 5 anomalias características e primordiais do complexo QRS que denotam patologias, são elas bloqueio de ramo, bloqueio intraventricular, taquicardia ventricular, batimento de origem ventricular e Síndrome de Wolff-Parkinson-White. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018).

Esta pesquisa baseou-se no trabalho intitulado *Detecção do Complexo QRS em Eletrocardiogramas com 12 derivações utilizando redes neurais convolucionais* (SILVA, 2023), aprimorando-se o trabalho feito considerando a presença das anomalias características do complexo QRS mencionadas no parágrafo acima.

## 1.1 Objetivo Geral

Aprimoramento da detecção do complexo QRS em exames de eletrocardiograma (ECG) que possuem arritmias cardíacas.

## 1.2 Objetivos específicos

- a) Avaliar a possibilidade de expandir a casuística de amostras de registros do complexo QRS dos exames de ECG na presença de anomalias, a partir da base *St. Petersburg INCART 12-lead Arrhythmia Database* (GOLDBERGER et al., 2000b).
- b) Avaliar se esse aumento de dados traz mais robustez ao método de detecção do complexo QRS proposto por Silva (2023).

## 1.3 Organização do trabalho

O trabalho está organizado entre os tópicos mostrados a seguir:

- Capítulo 1: Introdução;
- Capítulo 2: Revisão da literatura;
- Capítulo 3: Referencial teórico;
- Capítulo 4: Materiais e Métodos;
- Capítulo 5: Resultados e discussão;
- Capítulo 6: Conclusão.

O capítulo 1 tem por objetivo introduzir o trabalho, colocando as motivações de realização dele, além das fontes primordiais e organização da estrutura do processo de escrita dele.

O capítulo 2 consiste em apresentar os trabalhos realizados na área de aprendizado de máquina no que consiste na detecção do complexo QRS em eletrocardiogramas. Investiga-se trabalhos que utilizaram abordagem baseada em Processamento Digital de Sinais e Visão Computacional.

O capítulo 3 apresenta a fundamentação teórica do trabalho: eletrocardiograma padrão de 12 derivações, formas de onda presentes, tipos de anomalias relacionadas ao complexo QRS, processo de aumento de dados e redes neurais convolucionais.

O capítulo 4 descreve o conjunto de dados utilizado, o formato de leitura utilizado e suas particularidades, bem como o processo de aumento que foi realizado de forma a conter amostras de anomalias do complexo QRS. Também é discutido o método de treinamento das arquiteturas de redes neurais convolucionais utilizadas.

O capítulo 5 apresenta o resultado do aumento de dados e o aprimoramento obtido da detecção do complexo QRS comparando-se com os resultados da referência utilizada como base.

O capítulo 6 discute os aspectos totais e apresenta pontos de continuidade para a área de pesquisa escolhida.

## 2 Revisão Bibliográfica

Este capítulo tem por objetivo apresentar alguns trabalhos relacionados ao tema do projeto – detecção do complexo QRS – por meio da aplicação de técnicas de Processamento Digital de Sinais e Visão Computacional.

### 2.1 Detecção do complexo QRS em eletrocardiogramas com 12 derivações utilizando redes neurais convolucionais (SILVA, 2023)

Esta publicação é uma dissertação de mestrado que propõe um método para a detecção do complexo QRS utilizando um conjunto de três redes neurais convolucionais a partir da base de dados *St. Petersburg INCART 12-Lead*. O presente projeto, conforme já mencionado, trata-se da continuidade do apresentado por Silva (2023).

O pré-processamento dos sinais da base de dados compreendeu, a extração de amostras. Para cada derivação escolhe-se 24 amostras contendo 1136 pontos. Ao todo, obteve-se 1800 amostras em 75 registros, e a partir de então procedeu-se a anotação dos pontos Q, R e S. Partindo-se do pressuposto que os sinais estão sincronizados em todas as 12 derivações, a marcação de um complexo QRS em uma derivação é refletida para as demais.

A base de dados INCART é composta de pacientes com 10 tipos diferentes de anomalias cardíacas. Entretanto, o número de registros (pacientes) por anomalia cardíaca existente na base de dados é pequeno, chegando a algumas anomalias, como o bloqueio AV ter o registro de apenas um paciente. Assim, no procedimento descrito acima, a maioria das amostras extraídas correspondia a complexos QRS considerados normais – sem anomalias. Entretanto, uma avaliação detalhada na base de dados original, percebeu-se possibilidade de complementar e expandir o conjunto de dados com informações de complexos QRS com anomalias e, de certa forma, buscar o balanceamento dos dados entre as classes.

A partir das amostras anotadas o autor criou o padrão ouro, um sinal binário de que sinaliza o complexo QRS com um nível lógico 1 e os demais segmentos do sinal com 0. Em seguida as amostras foram concatenadas duas a duas de forma a se construir um *array* binário de dimensão 1136x2, caracterizado como o sinal padrão-ouro, que



será apresentado juntamente com as correspondentes amostras do sinal à entrada das redes neurais utilizadas para treinamento de aprendizado de máquina supervisionado.

A base de dados INCART é composta de pacientes com 10 tipos diferentes de anomalias cardíacas. Entretanto, o número de registros (pacientes) por anomalia cardíaca existente na base de dados é pequeno, chegando a algumas anomalias, como o bloqueio AV ter o registro de apenas um paciente. Conforme já mencionado, a maioria das amostras extraídas correspondia a complexos QRS considerados normais – sem anomalias. Tal fato que motivou a proposta do presente trabalho, ou seja, a inserção de novas amostras com a presença de anomalias do complexo QRS, com o fim de dar maior robustez ao método de detecção do complexo QRS.

## ***2.2 A detailed guide for quantification of myocardial scar with the Selvester QRS score in the presence of electrocardiogram confounders*** (LORING et al., 2011).

Esta publicação trata-se de um artigo científico disponível no *Journal of Electrocardiography* da Science Direct. Apesar deste projeto não objetivar a obtenção automática do índice de Selvester, tal referência é útil no sentido de entender como identificar de maneira correta as anomalias cardíacas relacionadas ao formato das ondas que compõem o complexo QRS. Adicionalmente, esse entendimento é importante no sentido de proceder corretamente o aumento de dados da base anotada por Silva (2023) com conteúdo de anomalias que contribuam para o aprimoramento da detecção do complexo QRS para casos de pacientes com enfermidades cardíacas.

### 3 Referencial Teórico

Neste capítulo será abordado os fundamentos teóricos a respeito do tema do trabalho, dividindo-se entre os conceitos relacionados ao eletrocardiograma, ciclo cardíaco, anomalias do ciclo cardíaco, como elas são observadas no exame de ECG e relacionados ao aprendizado de máquina, em específico o aprendizado supervisionado e as redes neurais convolucionais.

#### 3.1 Eletrocardiograma

Eletrocardiograma (ECG) é um exame médico através de instrumentação que registra a atividade elétrica do coração ao longo do tempo (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018). O sinal de ECG é conhecido como um traçado eletrocardiográfico que é gerado ao medir as variações dos potenciais elétricos gerados pelas células do coração durante o ciclo de funcionamento. Seu registro é um sinal em papel mostrando a atividade cardíaca. A análise do ECG pode evidenciar informações relacionadas à saúde do coração do paciente, como comportamentos anômalos, distúrbios no ritmo cardíaco, entre outros.

#### 3.2 Eletrofisiologia cardíaca

O coração possui quatro cavidades, chamadas átrio esquerdo (AE), átrio direito (AD), ventrículo esquerdo (VE) e ventrículo direito. Há também elementos de junção e de pulsação elétrica que é importante mencionar: o nó sinoatrial (SA), a junção atrioventricular, composta do nó atrioventricular (AV) e do ramo atrioventricular (RAV). O ramo esquerdo (RE), o ramo direito (RD), as *fibras de Purkinje* e o septo interventricular. Tais estruturas podem ser visualizadas na figura 1. Possui um sistema elétrico intrínseco que coordena sua atividade, permitindo que as câmaras cardíacas (átrios e ventrículos) se contraíam de forma sincronizada e rítmica para bombear sangue para os pulmões pelo processo de circulação pulmonar e em seguida levar esse sangue oxigenado aos demais órgãos do corpo. O sinal da contração cardíaca é sincronizado entre os músculos cardíacos através das *células marcapasso*, que executam o processo de polarização e despolarização cardíaca, responsável pelo ciclo cardíaco.




Figura 1 - Estruturas do coração. Adaptado de (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018).

O ciclo cardíaco se inicia no nó sinusal, e o sinal se propaga do átrio direito para o átrio esquerdo, este processo causa a contração do átrio e bombeia sangue para os ventrículos esquerdo e direito através das válvulas tricúspide e mitral, respectivamente. O sinal elétrico então se propaga pela musculatura atrial atingindo a junção atrioventricular (AV).

A junção atrioventricular atua realizando o chaveamento do impulso elétrico dos átrios para os ventrículos. Uma vez nos ventrículos, o impulso elétrico se propaga a partir dos ramos esquerdo e direito na parte central do coração para as extremidades ao longo das fibras de *Purkinje* e do septo interventricular, até a musculatura miocárdica. O ritmo se repete infinitamente ao longo da vida do órgão, iniciando no nó sinusal e terminando no epicárdio.

Nesse ínterim ocorrem dois processos. O primeiro deles, a despolarização trata-se do processo da ativação cardíaca nos átrios, enquanto o processo de repolarização ocorre quando as células cardíacas estão totalmente estimuladas e retornam ao estado de repouso. Tais processos se alternam e conferem as características das ondas elétricas que se observa em um exame de eletrocardiograma.

### 3.3 Formas de onda básicas do Eletrocardiograma

O eletrocardiograma registra a atividade elétrica das células cardíacas que realizam despolarização e repolarização. O ciclo cardíaco partindo da contração dos átrios, contração dos ventrículos e retorno do coração ao estado de repouso, reiniciando o ciclo, faz com que seja gerado um padrão de formas de onda que podem ser visualizadas

no eletrocardiógrafo, e analisadas em termos de suas medições em um papel com escala graduada. Num sinal de ECG padrão existem 5 formas de onda, 3 intervalos e 3 segmentos. Na tabela 1 apresenta-se as 5 formas de onda básicas do ECG e as respectivas etapas do ciclo cardíaco em que elas ocorrem. Na figura 2 apresenta-se uma ilustração de um ciclo cardíaco compreendendo as formas de onda básicas de ECG normal.

Tabela 1 - Formas de onda do ECG e sua relação com o ciclo cardíaco.

Onda ou Segmento	Etapa do Ciclo cardíaco
Onda P	Depolarização atrial
Complexo QRS	Depolarização ventricular
Segmento ST	Repolarização ventricular
Onda T	
Onda U	

- **Onda P:** a onda P é a primeira parte do traçado eletrocardiográfico e representa a despolarização dos átrios. Ela indica a contração dos átrios e a condução dos impulsos elétricos através do nó atrioventricular.
- **Complexo QRS:** esta é a parte mais proeminente do traçado eletrocardiográfico e objeto de estudo do trabalho desenvolvido. Representa a despolarização dos ventrículos e indica a ejeção de sangue das artérias. Existem anomalias referentes ao formato padrão do complexo QRS que podem variar dependendo da saúde do coração.
- **Segmento ST:** o segmento ST é uma parte reta do traçado que conecta o complexo QRS à onda T. Qualquer desvio nesse segmento pode ser indicativo de isquemia cardíaca, que é uma falta de suprimento sanguíneo adequado para o coração.
- **Onda T:** representa a repolarização dos ventrículos, preparando o coração para o próximo ciclo de contração. Qualquer anormalidade na forma ou na orientação da onda T pode indicar problemas cardíacos.

- **Intervalo QT:** o intervalo QT é medido a partir do início do complexo QRS até o final da onda T. Qualquer prolongamento ou encurtamento anormal desse intervalo pode estar relacionado a distúrbios do ritmo cardíaco.




Figura 2 - Formas de onda básica do ECG em um ciclo cardíaco. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018)

A análise clínica do eletrocardiograma também leva em consideração as estruturas entre as formas de onda, como os *segmentos* e os *intervalos*. Segmentos são definidos como os trechos do ECG que são limitados pelo fim de uma forma de onda e pelo início de outra. Intervalos são trechos do ECG tomados arbitrariamente que contém pelo menos uma forma de onda completa. No ECG padrão existem ao todo três segmentos básicos:

- **Segmento PR:** vai do fim da onda P até o início do complexo QRS. Indica o início da repolarização atrial, que continua durante o complexo QRS e se encerra durante o segmento ST.
- **Segmento ST:** vai do fim do complexo QRS até o início da próxima onda T, representa a repolarização ventricular. Em certas situações, o nível do segmento indica sinais de isquemia, a ser discutido no tópico referente a anomalias cardíacas.

- **Segmento TP:** vai do fim da onda T ao início da onda P. Representa o estágio de repouso elétrico do coração. Esse segmento é utilizado como o nível de referência para aferir desvio nos segmentos mencionados anteriormente.

Em adição aos segmentos, também há um conjunto de quatro intervalos que são costumeiramente medidos na avaliação clínica de um eletrocardiograma.

- **Intervalo PR:** medido do início da onda P até o início do complexo QRS.
- **Intervalo QRS:** medido do início ao fim do intervalo QRS.
- **Intervalo QT:** medido do fim da onda Q ao início da onda T.
- **Intervalo RR:** medido entre os dois pontos de maior amplitude de intervalos QRS consecutivos.

Na figura 3 ilustra-se todos os elementos do eletrocardiograma: formas de onda básicas, segmentos e intervalos.




Figura 3 - Elementos do eletrocardiograma. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018)

### 3.4 Complexo QRS

O complexo QRS é a entidade mais visível do eletrocardiograma e objeto central do trabalho desenvolvido neste projeto. Ele representa a transmissão do estímulo elétrico através dos ventrículos, e nem toda ocorrência deste evento em um eletrocardiograma apresenta as 3 ondas que formam o complexo bem definidas. Dado esse fato, é possível denominar representações análogas ao complexo QRS que também o definem de forma

parcial e ajudam a reconhecê-lo através das derivações de um eletrocardiograma. Cada correlato ao complexo QRS é mostrado na figura 4.

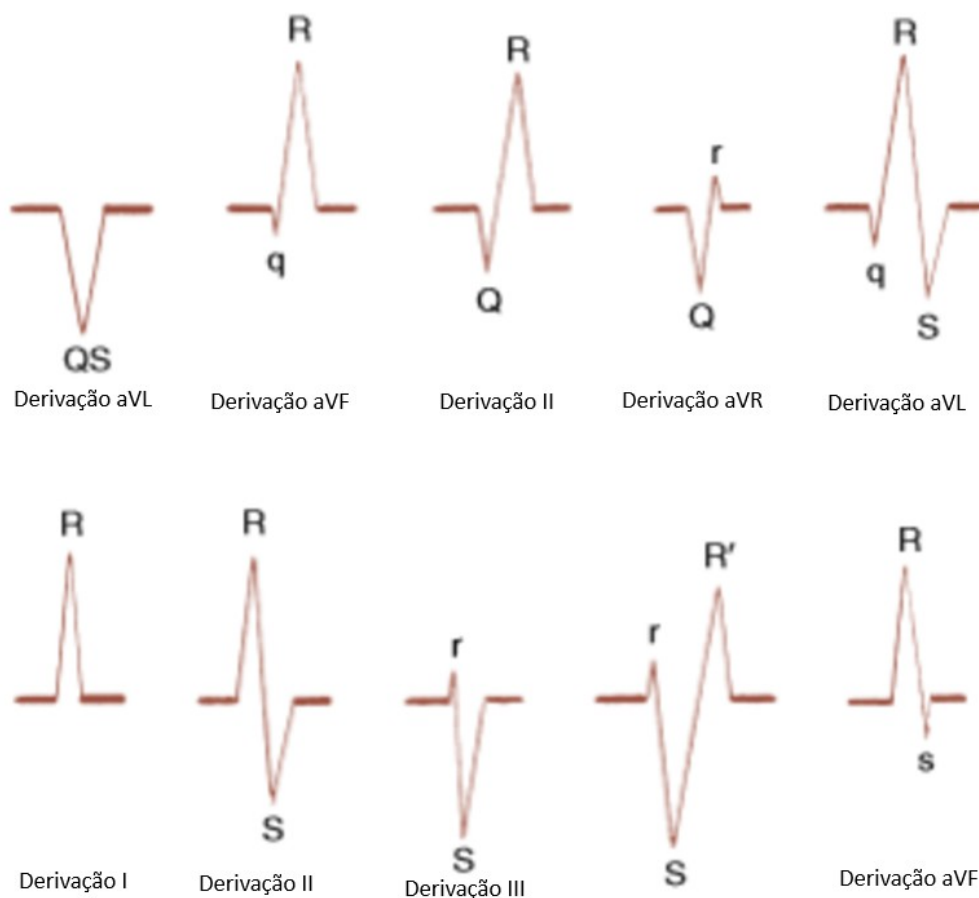


Figura 4 - Formas análogas do complexo QRS. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018)

### 3.5 Derivações do eletrocardiograma

O método de eletrocardiograma padronizado e utilizado amplamente é o eletrocardiograma de 12 derivações. As derivações são diferenças de potencial do sinal elétrico do ciclo cardíaco obtidas de pontos diferentes do corpo humano. Ao todo, existem dois grupos de derivações: seis derivações bipolares ou das extremidades (membros) e seis derivações precordiais (do peito).

- Derivações bipolares: registram a diferença de potencial entre dois pontos do corpo. Incluem as derivações dos membros: I, II, III, e as derivações aumentadas aVR, aVL e aVF.

- Derivações unipolares ou precordiais: estas derivações registram a atividade elétrica do coração em relação a um ponto de referência zero no centro do coração. Elas são chamadas de V1 a V6 e são colocadas no peito (precórdio).

A figura 5 mostra um esquema que indica o posicionamento dos eletrodos de um eletrocardiograma padrão de 12 derivações no corpo humano.




Figura 5 - Disposição dos eletrodos no eletrocardiograma padrão de 12 derivações.  
(SAINI; GUPTA, 2022)

Quanto às derivações das extremidades, os sinais elétricos de cada derivação são formados a partir da diferença de potencial entre dois pontos com referência ao centro do coração. O eletrodo do pé direito (RL) funciona como o potencial de terra, enquanto um eletrodo colocado no punho direito detecta potencial elétrico de mesma tensão que um eletrodo colocado no ombro direito, e o análogo ocorre para os mesmos pontos no lado esquerdo do corpo. Com isso é possível calcular as três primeiras derivações bipolares com base nas seguintes diferenças de potencial:



- Derivação I = Braço Esquerdo (LA) – Braço Direito (RA);
- Derivação II = Perna Esquerda (LL) – Braço Direito (RA);
- Derivação III = Perna Esquerda (LL) – Braço Esquerdo (LA).

A polaridade de cada derivação mostrada acima pode ser representada esquematicamente em um triângulo, chamado *Triângulo de Eindhoven* (SAINI; GUPTA, 2022). Esse esquema indica a disposição espacial das polaridades de cada derivação em relação ao posicionamento dos eletrodos. É também possível aferir a segunda derivação como uma soma das derivações primeira e terceira. A figura 6 mostra o esquema do Triângulo de Eindhoven.

Através da mesma ferramenta, é possível denominar as demais derivações de extremidades, chamadas derivações aumentadas: aVR, aVL e aVF. Estas derivações permitem uma visão tridimensional da atividade cardíaca a partir de diferentes ângulos. A soma dos potenciais das três derivações aumentadas é igual a zero.




Figura 6 - Triângulo de Eindhoven.

### 3.6 Anomalias do Complexo QRS

Dentre várias patologias cardíacas que podem ser observadas em um eletrocardiograma, cinco delas são diretamente relacionadas ao complexo QRS (SAINI; GUPTA, 2022). São elas:

- **Bloqueio de ramo:** é uma condição em que a condução elétrica em um dos ramos interventriculares é prejudicada. Isso resulta em um alargamento do complexo QRS no ECG. Existem dois tipos principais de bloqueio de ramo, o bloqueio do ramo direito e o bloqueio do ramo esquerdo (*left bundle Branch block – LBBB*, e *right bundle Branch block – RBBB*, em inglês, de acordo com a

literatura médica). Cada um desses bloqueios produz características de alargamento específicas do complexo QRS no eletrocardiograma. O bloqueio do ramo direito é observado na figura 7 e o bloqueio do ramo esquerdo é observado na figura 8.

- **Bloqueio intraventricular:** ocorre quando há um bloqueio na condução elétrica nos ventrículos. Isso pode caracterizar condições clínicas como cardiomiopatias e principalmente, o infarto do miocárdio. O bloqueio intraventricular resulta em um alargamento característico, diferente do bloqueio de ramo no ECG. É possível com essa informação, calcular métricas que indicam o tamanho da área fibrocicatricial do miocárdio decorrente do processo de infarto. (LORING et al., 2011). A figura 9 indica formações de infarto do miocárdio relacionadas ao bloqueio intraventricular.
- **Taquicardia ventricular:** é um ritmo cardíaco anormalmente rápido que origina nos ventrículos em vez dos átrios. No ECG, a taquicardia ventricular é caracterizada por um complexo QRS largo, em que não se permite visualizar cada uma das 3 ondas, mesmo com as variações indicadas na figura 4.
- **Batimento de origem ventricular:** às vezes, batimentos cardíacos prematuros originam-se nos ventrículos em vez dos átrios. Esses batimentos, chamados de “extrassístoles ventriculares”, produzem complexos QRS largos e anormais no ECG.
- **Síndrome de Wolff-Parkinson-White (WPW):** essa é uma condição cardíaca caracterizada por vias elétricas acessórias anômalas entre os átrios e os ventrículos. A presença de vias acessórias pode causar uma alteração no início do complexo QRS, conhecida como “onda delta”, que é característica da síndrome de WPW.




Figura 7 - Anomalias de bloqueio do ramo direito. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018)




Figura 8 - Anomalia de bloqueio do ramo esquerdo. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018)






Figura 9 - Anomalias do infarto do miocárdio – bloqueio intraventricular. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018)




Figura 10 - Padrões do QRS relacionados à síndrome WPW. (GOLDBERGER; GOLDBERGER; SHVILKIN, 2018)

### 3.7 Fundamentos das Redes Neurais Artificiais (RNA)

As redes neurais artificiais são modelos computacionais inspirados no funcionamento do cérebro humano, compostos por unidades de processamento chamadas neurônios artificiais, organizadas em camadas e interconectadas por pesos sinápticos. AGGARWAL, (2018). O funcionamento de uma rede neural artificial é

baseado no processamento de informações através de operações matemáticas, como somas ponderadas e funções de ativação não lineares.

A unidade de uma rede neural artificial pode ser entendida como uma estrutura chamada neurônio, que possui como entradas um vetor  $X_n$  em que  $n$  se refere a quantidade de entradas disponíveis multiplicadas por um vetor de pesos  $w_n$ . A estrutura do neurônio em si é responsável por fazer a somatória dos produtos de pesos pelas entradas. Este resultado é passado para uma função de ativação. A função de ativação determina se um neurônio deve ser ativado ou não com base no resultado de sua entrada. (GOODFELLOW; BENGIO; COURVILLE, 2016). A figura 11 mostra um diagrama esquemático de um *perceptron*.




Figura 11 - Diagrama esquemático de um neurônio ou modelo *perceptron*.

### **3.8 Redes Neurais Multicamadas**

O conceito de neurônio de ativação das redes neurais artificiais evoluiu e trabalhos ao longo do percurso propuseram o conceito de agrupamento de várias unidades de aprendizado em camadas. Com isso, surgiu-se o algoritmo de retropropagação e o conceito de “passe para a frente” (*feedforwarding pass*, do inglês), que possibilitam a criação de estruturas chamadas *perceptrons* multicamadas ou *multilayer perceptron*, do inglês, abreviado como MLP. A arquitetura base de um MLP, mostrada na figura 12, assume que todas as unidades de aprendizado são conectadas umas às outras, permitindo que o aprendizado seja transferido por mais unidades existentes. Esse processo gera camadas intermediárias chamadas camadas ocultas, que permite que a arquitetura MLP aprenda relações mais complexas entre as entradas que um único *perceptron*, tais relações podem conter características hierárquicas, que permitem que o modelo aprenda problemas mais complexos. (GOODFELLOW; BENGIO; COURVILLE, 2016), O processo de soma entre as camadas ocultas passa a ser chamado de *passe para frente*, enquanto o processo de atualização dos gradientes da função de perda é conhecido como o algoritmo de retropropagação, operação

fundamental do modelo multicamadas.

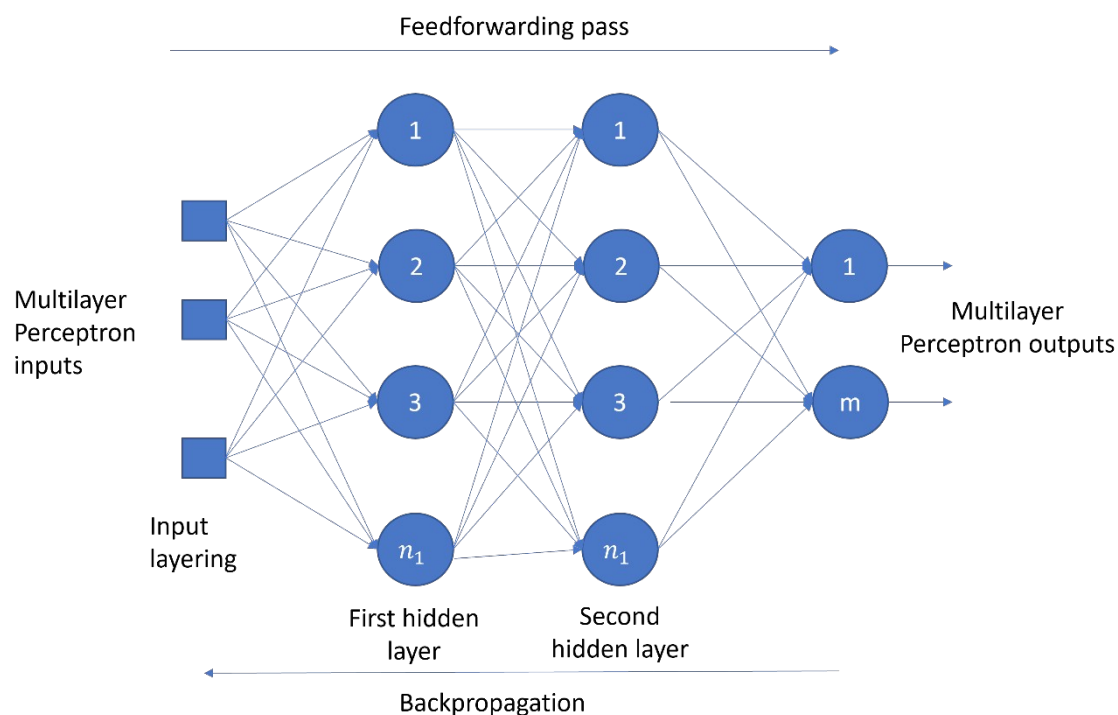


Figura 12 - *Perceptron* multicamadas. Adaptado de (SILVA, 2023).

### 3.9 Funções de Ativação

A função de ativação é uma etapa de uma rede neural artificial que confere a característica de não linearidade nas camadas de saída. Essa característica faz com que a rede neural seja capaz de aprender e representar relações complexas nos dados de entrada.

A função de ativação determina se a saída de uma rede neural será um nível lógico alto ou nível lógico baixo com base no resultado de sua entrada. Dentre os modelos não-lineares, as funções de ativação mais comumente utilizadas em redes neurais são:



- Sigmoid: mapeia os valores de entrada para um intervalo entre 0 e 1. É amplamente utilizada em problemas de classificação binária.
- Tangente hiperbólica (tanh): similar à sigmoide, entretanto mapeia os valores entre -1 e 1.
- ReLU (*Rectified Linear Unit*): Retorna zero para valores negativos e mantém os valores positivos intactos.
- Softmax: usada na camada de saída para problemas de classificação de várias classes. Retorna na saída uma distribuição de probabilidade, em que a soma de todas as saídas é igual a 1.

### 3.10 Aprendizado supervisionado e treinamento da rede neural

O método mais conhecido de se conferir aprendizado, ou treinar uma rede neural é o processo de aprendizado supervisionado. Esse processo consiste em separar um conjunto de dados para treinamento em que se conhece a classe de cada amostra, ou seja, a saída prevista para a rede. Uma vez treinada a rede constrói uma saída que é capaz de generalizar um novo resultado para uma nova entrada com base nas características observadas no conjunto de treinamento. Garante-se a qualidade do treinamento avaliando-se as previsões da rede em outros subconjuntos utilizados durante o processo de treinamento, como os subconjuntos de validação e teste. O termo supervisionado surge do fato de que existe uma entidade instrutora que informa à arquitetura cada associação para cada dado que ela está avaliando e aprendendo a característica.

### 3.11 Redes Neurais Convolucionais

A evolução dos trabalhos no campo de aprendizado de máquina bem como a criação de novos recursos computacionais que possibilitaram a resolução de problemas de aprendizado de máquina cada vez mais avançados, sobretudo com entradas cada vez mais complexas e multidimensionais, como imagens.

A Rede Neural Convolucional (CNN) é uma arquitetura apropriada para lidar com problemas em que as entradas são imagens, esse modelo foi proposto inicialmente por BENGIO; LECUN, (1997). Esse tipo de rede é desenhado para funcionar com estruturas de dados em formato de matriz, por exemplo, uma imagem. Como não há

uma conexão total das camadas intermediárias dos neurônios, ao contrário dos modelos MLP, as CNN são capazes de se especializar em regiões específicas da imagem, como em problemas de classificação em segmentação semântica. Existe um conjunto de operações realizadas por essas camadas, tais como a convolução discreta, a *batch normalization*, a unidade linear retificadora (ReLU) e a camada de *Pooling*. Estas operações são o conjunto que realiza a extração de características, e por fim, as camadas convolucionais são conectadas a um MLP, que realiza a classificação multimodal de fato.

As Redes Neurais Convolucionais utilizadas neste trabalho realizam um conjunto de operações a serem descritas a seguir:

- **Convolução discreta:** a camada convolucional realiza o processo da convolução discreta, em que uma máscara, também denominada de filtro ou kernel percorre toda a imagem e em cada localização executa-se a operação de soma de produtos das intensidades dos pixels pelos correspondentes coeficientes da máscara, resultando em uma matriz de características. (GONZALEZ; WOODS, 2006). Em aplicações de Processamento Digital de Imagens, os coeficientes da máscara definem a operação específica a ser realizada, enquanto em Aprendizado de Máquina os coeficientes são inicializados aleatoriamente e atualizados pelo algoritmo de retropropagação. (SILVA, 2023).
- **Batch Normalization:** é um processo que acelera a extração de característica e reduz a sensibilidade da rede em relação a inicialização de pesos e atualização dos vieses da arquitetura. É utilizada com o objetivo de evitar um fenômeno conhecido como fuga de gradientes, que ocorre quando o gradiente descendente se torna inalterado e o treinamento não converge para uma função de saída. Quando não há a convergência da rede, o algoritmo de retropropagação tende a atualizar os valores nas entradas com números aleatórios, realizando uma divergência do momento de aprendizado. A camada de normalização em lote corrige esse problema por meio do cálculo de médias e variações dos valores de atualização das iterações anteriores.
- **Pooling:** responsável por reduzir a dimensionalidade dos mapas de características gerados pela camada de convolução. Esse processo seleciona as características mais importantes das janelas de entrada, ajuda a evitar o superajustamento pela redução de parâmetros.



#### 4 Materiais e Métodos

O presente trabalho propõe o aprimoramento da detecção automática do complexo QRS em um sinal de eletrocardiograma padrão de 12 derivações, com base no processo proposto por Silva (2023). O trabalho mencionado realiza a detecção automática de complexos QRS por meio de redes neurais convolucionais, enquanto o presente tem por objetivo tomar o experimento proposto, e conforme mencionado no item 2.1, será realizada uma etapa adicional de aumento de dados para expandir o número de ocorrências de anomalias ao complexo QRS (vide item 3.6) e posteriormente repetir todo o experimento realizado por Silva (2023). A sequência metodológica é apresentada no diagrama da figura 13.

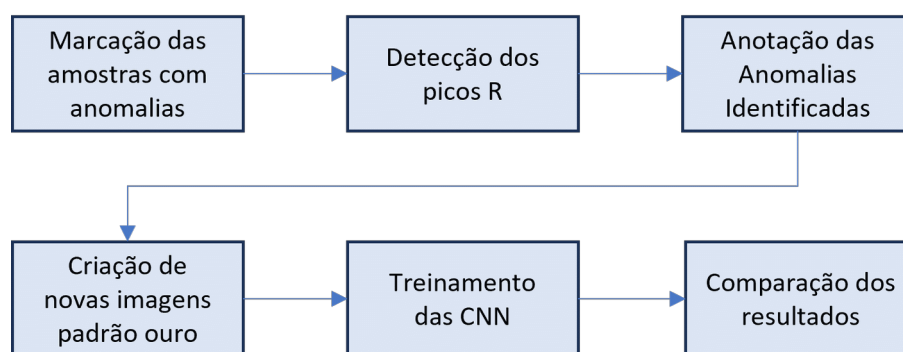


Figura 13 - Diagrama em blocos apresentando as etapas para aprimoramento da detecção do complexo QRS.

## 4.1 Materiais

O presente trabalho realiza a leitura dos dados e das anotações da base de dados *St. Petersburg INCART 12-Lead* e realiza a anotação de complexos QRS com padrões de anomalias. As anotações originais fornecidas por Goldberger (2000b) são utilizadas para facilitar a localização das anomalias em um conjunto de 175000 anotações de batimentos cardíacos, para as 12 derivações do eletrocardiograma.

O processo de criação das novas imagens de padrão ouro tem por objetivo repetir o processo proposto por Silva (2023) com o objetivo de gerar novas amostras de complexos QRS anômalos para treinamento, enquanto, ao fim do trabalho, compara-se os resultados objetivos a fim de se justificar o aprimoramento.

### 4.1.2 Base de Dados

A base de dados utilizada é a *St. Petersburg INCART 12-Lead*, fornecida pelo Instituto de Técnicas Cardiológicas de São Petersburgo, Rússia. O banco de dados é disponibilizado em diferentes plataformas para diferentes aplicações. Para o trabalho aqui realizado optou-se pela fonte original da plataforma *PhysioNet* (GOLDBERGER et al., 2000b).

A base de dados contém 75 gravações de 32 aparelhos *Holter* de pacientes diferentes com diversas condições cardíacas, sendo conduzidos para testes de doença coronária arterial. Ao todo, existem 175000 anotações de batimento cardíaco. Cada registro dura 30 minutos e contém as 12 derivações amostradas a 257 Hz. O trabalho publicado por Silva (2023) transformou os arquivos originais de extensão HEA contendo as gravações de eletrocardiograma para arquivos de dados próprios do MATLAB®, de extensão MAT. Tais arquivos MAT foram utilizados como ponto de partida para o trabalho aqui desenvolvido.

Os dados foram coletados de pacientes em testes para doença arterial coronariana, A casuística foi de 17 homens e 15 mulheres, com idades entre 18 e 80 anos, sendo a média das idades igual a 58 anos. Nenhum dos pacientes tinha aparelhos marcapasso instalados em seus corações. A maioria apresentava batimentos cardíacos ectópicos ventriculares. Nas seleções dos registros a serem incluídos na base de dados,

foi dada preferência a indivíduos com ECG compatíveis com isquemia, doença arterial coronariana, anomalias de condução e arritmias (GOLDBERGER et al., 2000a). As observações dos indivíduos selecionados quanto a patologias são observadas na tabela 2:

Tabela 2 - Relações de patologias cardíacas presentes na base de dados INCART.

Diagnóstico	Pacientes
Infarto do Miocárdio Agudo	2
Ataque isquêmico transitório (angina de peito)	5
Infarto do Miocárdio Anterior	4
Doença arterial coronariana com hipertensão	7 (4 com ECGs consistentes com hipertrofia ventricular esquerda)
Disfunção do nó sinusal	1
Ectopia supraventricular	18
Fibrilação atrial ou SVTA	3 (2 com FA paroxística)
Síndrome WPW	2
Bloqueio AV	1
Bloqueio de ramificação do pacote	3

#### 4.1.2 Definição do ambiente de desenvolvimento

Utilizou-se um computador com processador Intel Core i7-8550U CPU @ 1.80GHz 1.99GHz, 20GB de memória RAM instalada e uma GPU NVIDIA GeForce MX150 com 2GB de memória dedicada e CUDA Toolkit versão 8 e unidades de armazenamento *Solid State Drive* (SSD) com 1,2TB de capacidade, com sistema operacional Windows 11.

O *software* base para leitura, anotação, treinamento e avaliação foi o MATLAB® versão 2022b com as *toolboxes* *Neural Network*, *Computer Vision System* e

*Digital Signal Processing*. Para anotação dos dados, utilizou-se o utilitário *Signal Labeler*, disponível para instalação separada na janela de *add-ons* do MATLAB®.

## 4.2 Métodos

### 4.2.1 Algoritmo de marcação das anomalias

Ao se consultar os arquivos originais da base de dados *St-Petersburg INCART 12-lead*, percebeu-se a existência de arquivos extensão ATR. Estes arquivos não foram manipulados no trabalho realizado por Silva (2023), mas aqui foram utilizados para se obter os pontos no ECG de ocorrência das anomalias indicadas pela tabela 2.

```
% Limpa a janela de comando
clc;

% Define os limites do intervalo de amostras
primeiraAmostra = 1;
ultimaAmostra = 1136;

% Carrega os dados do paciente I01
nomeArquivoECG = 'I75';
[sinalECG, frequenciaAmostragem, tempo = rdsamp(
    nomeArquivoECG, primeiraAmostra, ultimaAmostra);

% Carrega as etiquetas dos picos R a partir do arquivo 'atr'
[etiquetasPicosR, tipoEtiqueta,
    subtipo, canal, numero, comentarios] = rdann(
    nomeArquivoECG, 'atr', primeiraAmostra, ultimaAmostra)

% Plota todos os canais do sinal
plot(sinalECG);
hold on;

% Plota marcadores nas posicoes das Etiquetas Picos R
% ajustando-se ao canal 1 do sinal
plot(etiquetasPicosR, sinalECG(etiquetasPicosR, 1), '|');

% Cria uma matriz de marcadores com as posições e valores do sinal
marcadores = [etiquetasPicosR, sinalECG(etiquetasPicosR, 1)];

% Plota os rótulos dos marcadores
text (etiquetasPicosR, sinalECG(etiquetasPicosR, 1), tipoEtiqueta);

hold off;
```

Figura 14 – Identificação das anomalias registradas nos arquivos ATR.

A figura 14 apresenta o algoritmo desenvolvido para o registro das anomalias presentes, segundo os arquivos ATR. A função principal do sistema de anotação de dados desenvolvido durante o trabalho é realizar a leitura de cada uma das 75 gravações e armazenar em uma variável no espaço de trabalho do MATLAB®. Em seguida, com o uso do utilitário *SignalLabeler*, cada variável é importada para que se realize a anotação dos complexos QRS com anomalias.

Nos arquivos de anotação de anomalias ATR, observou-se a identificação de três tipos de marcações com as letras V, N e J, que possuem os significados abaixo:

- V: anomalia referente a formas de onda;
- N: anomalia referente a segmento;
- J: picos normais.

Para isso, filtrou-se os sinais caracterizados como picos N e J e deixou-se apenas o sinal com pico V, que dentre os quais, compreendem-se as anomalias de complexo QRS que se desejava anotar, conforme algoritmo demonstrado na figura 15.

```
function visualizarIntervalo(intervalos_X, intervalos_Y, posicoes_V, posicao_V_Y, numb_plot)
    figure;

    % Plota o intervalo de dados
    plot(intervalos_X(numb_plot,:), intervalos_Y(numb_plot,:), 'b');
    hold on;

    % Plota a posição V e seu equivalente em Y
    plot(posicoes_V(numb_plot), posicao_V_Y(numb_plot), 'ro', 'MarkerFaceColor', 'r');
    hold off;

    xlabel('Índice');
    ylabel('Valor');
    title('Visualização do Intervalo');

    legend('Intervalo de Dados', 'Posição V');
end
```

Figura 15 - Filtragem dos picos V.

#### 4.2.2 Anotação dos complexos QRS para aumento de dados

Após realizar o carregamento dos dados no espaço de trabalho do MATLAB® com os algoritmos descritos nas figuras 14 e 15, importou-se as variáveis criadas no aplicativo *SignalLabeler*. O espaço de trabalho do utilitário é mostrado na figura 16:



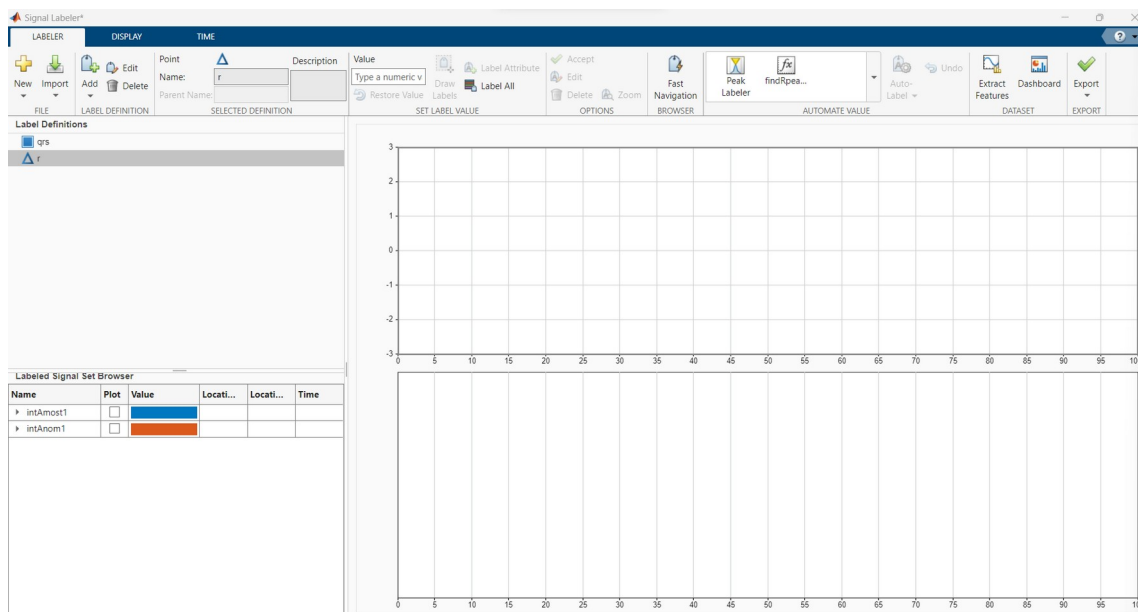


Figura 16 - Aspecto visual do *SignalLabeler*.

Após o carregamento dos sinais, o processo seguinte é criar os *Label Definitions*, que são as variáveis que armazenam os rótulos anotados dentro de uma estrutura de dados chamada *LabeledSignalSet*, resultando do processo de anotação. Cada anotação gera um *LabeledSignalSet*, e dados anotados juntos na mesma sessão do *SignalLabeler* são agrupados em um *CellArray*. Estes dados são convertidos para extensão MAT. Quanto aos rótulos, foram criadas as seguintes características:

- *QRSregions*: do tipo categórico e ROI (*region of interest*).
- *Rpeaks*: tipo numérico.

Cada uma dessas características acima fica disponíveis ao clique do *mouse* na tela. Quando se seleciona uma região e se arrasta o ponteiro do mouse, habilita-se a variável *QRSregions*. Quando apenas se clica em uma posição do sinal, habilita-se a variável *Rpeaks*. Na figura 17, mostra-se um exemplo do processo de anotação de uma amostra através do aplicativo *SignalLabeler*.




Figura 17 - Exemplos de complexos quatro complexos QRS normais e um anômalo anotados.

#### 4.2.3 Processos pós-anotação para aumento de dados

Após o processo de anotação, registrou-se regiões anômalas no complexo QRS marcadas pelo algoritmo das figuras 15 e 16. Estas anotações são exportadas como um arquivo de extensão MAT e formato *LabeledSignalSet* através da função *export* do próximo aplicativo de *SignalLabeler*. Em seguida, carrega-se o arquivo MAT resultante no próprio espaço de trabalho do MATLAB®, para os processos pós-anotação.

A estrutura de *LabeledSignalSet* possui o sinal de ECG e os intervalos de picos R e complexos QRS em estruturas de tabelas separadas. Para a leitura dos dados anotados e possibilitar a transformação para padrão-ouro, é necessário realizar o referenciamento dos intervalos marcados nas anotações com os sinais de eletrocardiograma de fato. Para isso, utilizou-se um algoritmo para remover as respectivas tabelas da estrutura de dados anotados e armazená-las em variáveis de tabela ou *cell arrays* do MATLAB®. O processo também é realizado iterativamente para cada amostra. Na figura 18 mostra-se a função utilizada para realizar o processo para uma das amostras.

Uma vez que os dados de sinais de eletrocardiograma (*result\_qrs*) e máscaras de anotação (*results\_mvals*) estejam sincronizados no espaço de trabalho do MATLAB®, é possível prosseguir com a normalização dos intervalos e geração das imagens padrão-ouro.

```

close all;clear;clc;
load QRS- anotado-101-200.mat;

% Initialize a cell array to store the results for each iteration
results_qrs = cell(100, 1);
results_mvals = cell(100, 1);

for i = 1:100
    j = 100 + i;
    variableName = ['intAmost', num2str(j)]; % Generate variable name dynamically
    qrs = getSignal(ls, i);
    t = qrs.Time;
    sinal = qrs.(variableName); % Access the variable using dynamic name
    mvals = getLabelValues(ls, 1, 'QRSregions');

    % Store the results for this iteration
    results_qrs{i} = qrs;
    results_mvals{i} = mvals;
end

% Now 'results' contains the results for all 200 iterations

```

Figura 18 - Algoritmo que relaciona amostras e anotações.

#### 4.2.4 Normalização dos intervalos

O processo de normalização dos intervalos consiste levar as magnitudes do sinal de eletrocardiograma contidos nos intervalos marcados pela anotação dos complexos QRS, para o nível de 255, pois estamos usando uma escala de cinza de 8 bits, enquanto as magnitudes restantes são levadas para o valor zero. Isso resulta em um sinal de característica de pulso, que na etapa adiante será convertido na imagem padrão ouro a ser utilizada no treinamento do conjunto de redes neurais convolucionais utilizados no experimento proposto por Silva (2023).

O algoritmo da figura 19 demonstra o processo de leitura dos intervalos e normalização para uma amostra. O processo foi realizado de forma iterativa para todas as amostras disponíveis e as doze derivações. Na figura 20 Apresenta-se uma amostra de sinal de ECG lido pelo utilitário *SignalLabeler* e o correspondente sinal resultante do processo de normalização dos intervalos.

```

% Initialize the output array as zeros with the same size as results_qrs{1}
output = zeros(size(results_qrs{1}.intAmost101));

% Find the highest Time index in results_qrs{1}
highest_time = max(results_qrs{1}.Time);


% Iterate through the rows of results_mvals{1}
for i = 1:size(results_mvals{1}, 1)
    lower_limit = results_mvals{1}.ROIlimits(i, 1);
    upper_limit = results_mvals{1}.ROIlimits(i, 2);

    % Check if the interval is within the highest Time index
    if lower_limit <= highest_time
        % Find the indices within the interval and set them to 255
        indices = results_qrs{1}.Time >= lower_limit & results_qrs{1}.Time <= min(upper_limit, highest_time);
        output(indices) = 255;
    end
end


% Now, 'output' contains the desired values (255 or 0)

```

Figura 19 - Algoritmo de normalização dos intervalos.



(a)



(b)

Figura 20 – (a) Sinal de eletrocardiograma com os complexos QRS visíveis (b) sinal normalizado. correspondente

#### 4.2.5 Transformação dos novos dados anotados em imagem padrão-ouro

A última etapa do processo de aumento de dados da base *St. Petersburg INCART 12-Lead* é transformar os intervalos normalizados (figura 20 - b) na etapa anterior em imagens padrão-ouro (*Ground Truth*). O processo consiste em concatenar as amostras duas a duas, de forma que se tenha matrizes de tamanho 2x1136, com dois níveis de cinza, o valor de 255 (pixel branco), indicando os intervalos que contém complexos QRS, sejam eles anomalias ou não, e o valor de 0 (pixel preto), que contém todos os demais valores do eletrocardiograma, sejam ruídos ou outras formas de ondas básicas.

O algoritmo que realiza a transformação dos sinais normalizados em imagens do padrão-ouro e salva as amostras em uma pasta separada para cada derivação é mostrado na figura 22.

```
clc;
for r=1:12
    X = cat(1, amostras{1,r}, amostras{2,r}, amostras{3,r}, amostras{4,r}, amostras{5,r}(1:4, :));
    cont=0;
    for i=1:size(X,1)/2
        inf=(i-1)*2+1;
        sup=i*2;
        a=X(inf:sup,:);
        %b=mat2gray(a);
        %trocar o caminho para salvar
        mkdir("Inputs"+sprintf('%d',r))
        filename="Inputs"+sprintf('%d',r)+"\im_"+sprintf('%03d',i)+".png";
        imwrite(a,filename);
    end
    i=i+1;
end
```

Figura 21 - Algoritmo de transformação de intervalos anotados para padrão-ouro.

#### 4.2.6 Definição das Arquiteturas de Redes Neurais Convolucionais

As arquiteturas de CNNs que foram utilizadas para o treinamento com o conjunto de dados aumentado para detecção do complexo QRS nas 12 derivações do eletrocardiograma são as mesmas definidas pelo experimento proposto por Silva, (2023). O aprendizado corresponde a uma segmentação semântica, que avalia e classifica cada pixel como correspondente a uma classe. São duas classes propostas para o experimento, segmento QRS ou o complementar. Em resumo, são selecionadas 3 arquiteturas diferentes de Redes Neurais Convolucionais.

A primeira arquitetura, chamada CNN 1 possui uma entrada de dimensões de 2x1136x1, um subgrupo de camadas de convolução de 25, 50 e 100 filtros, em seguida

de uma camada de normalização em lote (*batch normalization*), função de ativação de unidade retificadora linear (ReLU) e camada de amostragem (*maxpooling*). Na figura 22 observa-se um diagrama esquemático da arquitetura da Rede Neural.

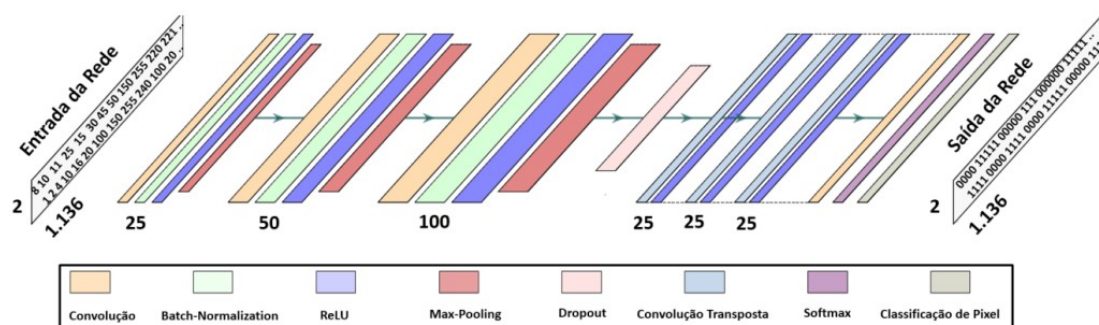


Figura 22 - Arquitetura da CNN 1. (SILVA, 2023)

As segundas e terceiras arquiteturas, chamadas respectivamente de CNN 2 e CNN3 possuem mesmo tamanho da entrada e mesmas unidades de normalização em lote, camada de amostragem e função de ativação, diferindo da arquitetura da CNN 1 na quantidade de filtros das camadas que realizam a convolução. A CNN2 possui 32, 64 e 128 filtros nas camadas de convolução, e a CNN3 possui 75, 150 e 300 filtros nas camadas de convolução. As figuras 23 e 24 mostram um diagrama esquemático da representação de ambas as arquiteturas.

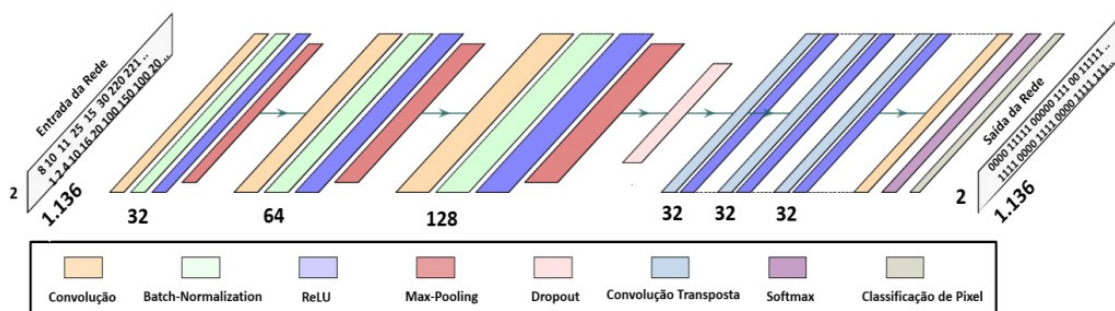


Figura 23 - Arquitetura da CNN 2. (SILVA, 2023).

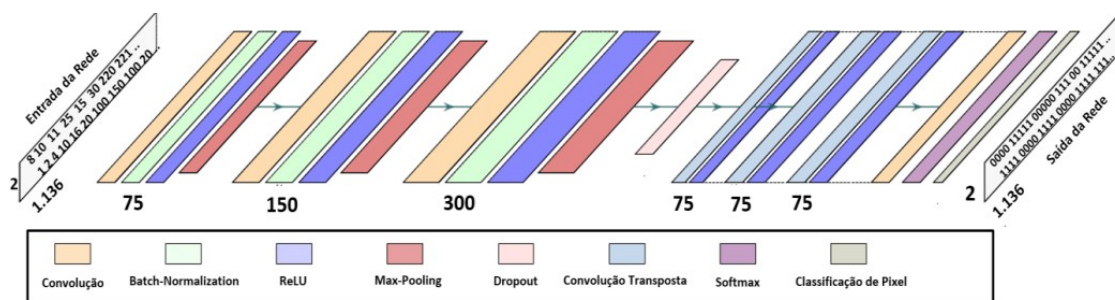


Figura 24 - Arquitetura da CNN 3. (SILVA, 2023).

#### 4.2.7 Execução dos treinamentos

A divisão do conjunto de dados realizada foi: 80% para o subconjunto de treinamento e 20% para o conjunto de teste. Outras configurações são o uso do otimizador ADAM, taxa de aprendizado de 0,0003, decaimento do gradiente de 0,99, número de épocas máximo de 300, tamanho de lote de 64 imagens por vez e embaralhamento dos dados a cada época de treinamento. O executa-se um processo de treinamento por vez para cada derivação, sendo ao todo 36 execuções - 12 derivações para 3 arquiteturas.

#### 4.2.8 Pós-Processamento

A etapa de pós-processamento visou a retirada de falsos positivos relativos a ondas P ou ruídos no sinal. Existem 3 passos para realizar o pós-processamento, descritos a seguir:

- Passo 1: utiliza-se o resultado da rede neural como uma máscara para filtrar na imagem de entrada os intervalos identificados.
- Passo 2: obtêm-se os pontos de máximo e mínimo nos intervalos identificados e calcula-se a altura.
- Passo 3: Obtêm-se a média das amostras para o intervalo obtido e aplica-se a regra: se a altura do intervalo for maior que a média, trata-se de um complexo QRS verdadeiro, se for menor, corresponde-se a um falso positivo detectado pela rede neural.

#### 4.2.9 Métricas de Avaliação de Desempenho

As métricas de avaliação de desempenho são baseadas nas mais comuns métricas de classificação utilizadas na literatura correspondente a aprendizado de máquina. O modelo treinado pode retornar como predição 4 tipos de dados que podem ser relacionados da seguinte forma:

- TP: verdadeiros positivos (caso positivo previsto corretamente como positivo);
- TN: Verdadeiro negativo (caso negativo previsto corretamente como negativo);
- FP: falso positivo (caso negativo previsto incorretamente como positivo);
- FN: falso negativo (caso positivo previsto incorretamente como negativo).

A precisão, o recall e o f1-score foram elencados como métricas de avaliação do desempenho. Cada métrica é tomado por sessão de treinamento, derivação a derivação nas 3 arquiteturas definidas.

A precisão é definida como a quantidade de classificações positivas são realmente classificados como positivos, conforme a equação (1).

$$Precisão = \frac{TP}{TP + FP} \quad (1)$$

Uma alta precisão significa que a maioria dos pixels identificados como positivos são de fato positivos, ao passo que uma baixa precisão indica que muitos pixels negativos foram incorretamente identificados como positivos.

O *recall* mede a proporção de detecções corretamente positivas em relação a soma de verdadeiros positivos e falsos negativos, como mostra a equação (2):

$$Recall = \frac{TP}{TP + FN} \quad (2)$$

Quanto mais elevado o *recall*, o classificador é melhor em identificar corretamente os positivos.

O *F1-score* é uma métrica que relaciona a precisão e o recall, que foi utilizada no experimento proposto por Silva (2023) como uma medida mais representativa do desempenho geral da detecção do complexo QRS. A equação (3) mostra a equação do *F1-score*.

$$F1\ score = \frac{2 \times Precisão \times Recall}{Precisão + Recall} \quad (3)$$





## 5 Resultados e Discussões

Neste capítulo apresenta-se e discute os resultados dos experimentos da etapa de treinamento das arquiteturas de rede neural convolucionais propostas para cada uma das derivações de um eletrocardiograma padrão. Em seguida, compara-se o resultado obtido com os resultados apresentados na publicação de Silva (2023), indicando-se a influência do processo de aumento de dados contendo anomalias do complexo QRS para o aprimoramento da segmentação semântica.

### 5.1 Aumento de Dados


A base de dados de imagens Padrão-Ouro consolidada por Silva (2023) contém ao todo 480 itens por derivação, totalizando 5760 itens com amostras referentes a complexos QRS normais. Com o aumento de dados realizado no trabalho aqui descrito dos itens 4.2.1 a 4.2.5, acrescentou-se ao conjunto consolidado um total de 80 itens por derivação, resultando em novas 960 imagens Padrão-Ouro com informações referentes a anomalias cardíacas referentes ao complexo QRS, conforme item 3.6.

A base de dados consolidada após o experimento de aumento de dados passou a ter 560 imagens por derivação, totalizando 6720 itens, o que representa um acréscimo de informação de 16,67% em relação ao conjunto consolidado por Silva (2023). Com o exposto, considera-se que o conjunto de dados incrementado possui melhor representatividade de informações em relação à base de dados *St. Petersburg INCART 12-Lead* (GOLDBERGER et al., 2000a).


### 5.2 Convergência da Rede Neural Convolucional

A convergência da Rede Neural Convolucional é definida como a atualização dos parâmetros de modelo até o ponto em que a função de perda atinge um valor mínimo. Esse é o ponto em que se assume que o modelo aprendeu todas as características possíveis para aquele conjunto de dados com base nos hiper parâmetros selecionados. Esse processo leva um determinado número de épocas.

Cada experimento desenvolvido neste trabalho, como descrito no item 4.2.7 Execução dos treinamentos, levou 300 épocas para ser executado. Como exemplo da evolução das métricas de treinamento, mostra-se na figura 25 uma das saídas do MATLAB® para dado experimento entre os 36 executados.



(a)



(b)

Figura 25 - (a) Gráfico de convergência de precisão e (b) perda em função do número de épocas, para a primeira derivação na arquitetura CNN1.

Assim como no experimento proposto por Silva (2023), manteve-se para as três arquiteturas as 1800 iterações e 300 épocas, com taxas de aprendizado mantidas constantes ao longo do treinamento. Da mesma forma, observou-se uma diferença de

tempo entre as derivações e as arquiteturas, entretanto, os tempos de execução de treinamento foram maiores por dois motivos: mais dados devido ao de aumento de dados realizado e menos recurso computacional (conforme item 4.1.1 Definição do ambiente de trabalho) em comparação ao experimento base.

### 5.3 Análise dos Resultados

Na tabela 3 exibe-se os resultados obtidos no experimento base executado e proposto por Silva, (2023). O autor apresenta os dados para precisão, *recall* e *F1-score* para cada uma das 12 derivações separadamente e ao final calcula a média para cada uma das métricas, para ambas as instâncias – antes e após o processamento descrito no item 4.2.8.

Na tabela 4 exibe-se os resultados obtidos após se realizar o aumento de dados objetivo deste trabalho, conforme descrito nos itens 4.2.1 a 4.2.5. Com auxílio da tabela 5, é possível observar para cada derivação a diferença percentual e média entre as métricas obtidas antes e depois do pós-processamento. Obtém-se os melhores resultados absolutos por derivação quanto de maior diferença percentual na terceira arquitetura (CNN3, figura 24) para as três métricas avaliadas – precisão, *recall* e *F1-score*.

Observa-se o comportamento de crescimento das métricas em relação ao resultado antes e depois da etapa de pós-processamento para os resultados com aumento de dados obtidos durante a execução deste trabalho, na Tabela 4, algo que pode ser comprovado observando o padrão de diferenças percentuais apresentados na Tabela 5.

Por fim, na tabela 6 tem-se o comparativo entre a arquitetura com melhor desempenho obtido no experimento realizado por Silva (2023), que se trata da CNN2 apresentada na figura 23, e a arquitetura com melhor desempenho obtido no experimento com aumento de dados realizado por este trabalho, que se trata da CNN3, apresentada na figura 24.

Considerando apenas as métricas médias percentuais obtidas ao final da etapa de Pós-Processamento, tem-se uma diferença de 1,77% para a Precisão, 2,03% para o *Recall* e 1,91% para o *F1-Score*, com os valores mais elevados sendo dos dados obtidos no experimento realizado por Silva (2023). Da mesma forma, cada derivação apresenta métricas mais elevadas no experimento de Silva (2023) que no experimento com aumento de dados aqui realizado, apesar de que nenhum valor é inferior o suficiente a

ponto de se poder afirmar que o aumento de dados causa uma diferença de desempenho relevante entre as arquiteturas.

Há alguns fatores a se considerar, entre eles a inicialização aleatória dos pesos das arquiteturas de Redes Neurais Convolucionais ao início do treinamento, e o fato de se realizar a operação de aumento de dados, significa que o Padrão-Ouro composto ao se repetir o experimento proposto por Silva (2023) tem maior representatividade em relação à base de dados *St.Petersburg INCART 12-Lead* que o conjunto de dados anterior.

Com o exposto, pode-se afirmar que o trabalho desenvolvido contribui para o experimento proposto por Silva (2023) no objetivo de complementar o Padrão-Ouro de sinais de complexos QRS do experimento base, bem como no método de se converter um sinal de eletrocardiograma, de característica sequencial, para um *array* binário, e poder então utilizar Redes Neurais Convolucionais para extrair informações relacionadas ao complexo QRS através da técnica de segmentação semântica das amostras de eletrocardiograma.

A publicação de Loring *et. Al.* (2011), revista no item 2.2, utiliza apenas técnicas de Processamento Digital de Sinais e prática clínica com o uso de eletrocardiogramas para quantificar o tamanho da cicatriz em pacientes que sofreram infarto do miocárdio. O trabalho realizado por Silva (2023) utiliza de técnicas de Aprendizado de Máquina e propõe um experimento de geração do Padrão-Ouro para classificação do complexo QRS, e o trabalho realizado aqui utiliza-se do método anterior para incrementar o Padrão-Ouro gerado com dados de anomalias.

Tabela 3 - Resultados das métricas obtidos por Silva (2023) para as arquiteturas propostas pelo experimento base sem aumento de dados.

Derivação	CNN1						CNN2						CNN3					
	Antes do Pós-Processamento			Depois do Pós-Processamento			Antes do Pós-Processamento			Depois do Pós-Processamento			Antes do Pós-Processamento			Depois do Pós-Processamento		
	Prec. (%)	Recall (%)	F1-Score (%)	Prec. (%)	Recall (%)	F1-Score (%)	Prec. (%)	Recall (%)	F1-Score (%)	Prec. (%)	Recall (%)	F1-Score (%)	Prec. (%)	Recall (%)	F1-Score (%)	Prec. (%)	Recall (%)	F1-Score (%)
I	66,2 <sub>2</sub>	99,73	79,59	99,96	99,73	99,85	75,0 <sub>3</sub>	99,79	85,66	99,95	99,79	99,87	66,1 <sub>2</sub>	99,77	79,53	99,92	99,77	99,85
II	64,3 <sub>9</sub>	100,0 <sub>0</sub>	78,34	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00	71,3 <sub>0</sub>	100,0 <sub>0</sub>	83,25	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00	64,6 <sub>6</sub>	100,0 <sub>0</sub>	78,54	99,96	100,0 <sub>0</sub>	99,98
III	69,2 <sub>4</sub>	100,0 <sub>0</sub>	81,82	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00	71,3 <sub>8</sub>	100,0 <sub>0</sub>	83,3	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00	69,0 <sub>5</sub>	100,0 <sub>0</sub>	81,69	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00
aVR	79,0 <sub>0</sub>	99,94	88,25	99,83	99,94	99,89	83,1 <sub>3</sub>	100,0 <sub>0</sub>	90,79	99,94	100,0 <sub>0</sub>	99,97	79,7	99,94	88,68	99,77	99,94	99,85
aVL	61,3 <sub>4</sub>	99,56	75,91	99,94	99,56	99,75	72,2 <sub>4</sub>	99,22	83,61	99,95	99,22	99,59	61,3 <sub>4</sub>	99,53	75,9	99,97	99,53	99,75
aVF	71,5 <sub>9</sub>	100,0 <sub>0</sub>	83,45	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00	79,5 <sub>2</sub>	100,0 <sub>0</sub>	88,59	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00	71,1 <sub>8</sub>	100,0 <sub>0</sub>	83,16	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00
V1	69,8 <sub>5</sub>	100,0 <sub>0</sub>	82,25	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00	76,5 <sub>0</sub>	100,0 <sub>0</sub>	86,69	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00	68,9 <sub>2</sub>	100,0 <sub>0</sub>	81,6	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00
V2	75,2 <sub>9</sub>	99,68	85,79	100,0 <sub>0</sub>	99,68	99,84	78,7 <sub>7</sub>	99,83	88,06	100,0 <sub>0</sub>	99,83	99,91	74,9 <sub>5</sub>	99,48	85,49	100,0 <sub>0</sub>	99,48	99,74
V3	63,9 <sub>4</sub>	100,0 <sub>0</sub>	78,01	99,97	100,0 <sub>0</sub>	99,98	72,6 <sub>7</sub>	100,0 <sub>0</sub>	84,17	99,95	100,0 <sub>0</sub>	99,98	63,2 <sub>4</sub>	100,0 <sub>0</sub>	77,48	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00
V4	66,3 <sub>8</sub>	99,96	79,78	99,92	99,96	99,94	69,9 <sub>6</sub>	99,96	82,31	99,96	99,96	99,96	66,7 <sub>5</sub>	99,96	80,05	99,96	99,96	99,96
V5	60,8 <sub>8</sub>	100,0 <sub>0</sub>	75,68	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00	75,9 <sub>0</sub>	100,0 <sub>0</sub>	86,3	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00	60,9 <sub>9</sub>	100,0 <sub>0</sub>	75,77	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00
V6	63,6 <sub>2</sub>	100,0 <sub>0</sub>	77,77	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00	90,9 <sub>0</sub>	100,0 <sub>0</sub>	95,23	100,0 <sub>0</sub>	100,0 <sub>0</sub>	100,00	63,7 <sub>3</sub>	100,0 <sub>0</sub>	77,85	99,97	100,0 <sub>0</sub>	99,98
Média	67,6 <sub>5</sub>	99,9 <sub>1</sub>	80,55	99,9 <sub>7</sub>	99,9 <sub>1</sub>	99,94	76,4 <sub>4</sub>	99,9 <sub>0</sub>	86,50	99,9 <sub>8</sub>	99,9 <sub>0</sub>	99,94	67,5 <sub>5</sub>	99,8 <sub>9</sub>	80,48	99,9 <sub>6</sub>	99,8 <sub>9</sub>	99,93

Tabela 4 - Resultados das métricas obtidas na execução deste trabalho para as arquiteturas proposta após a realização do aumento de dados.

Derivação	CNN1						CNN2						CNN3					
	Antes do Pós-Processamento			Antes do Pós-Processamento			Antes do Pós-Processamento			Antes do Pós-Processamento			Antes do Pós-Processamento			Depois do Pós-Processamento		
	Pre c. (%)	Reca II (%)	F1-Score (%)	Pre c. (%)	Reca II (%)	F1-Score (%)	Pre c. (%)	Reca II (%)	F1-Score (%)	Pre c. (%)	Reca II (%)	F1-Score (%)	Pre c. (%)	Reca II (%)	F1-Score (%)	Pre c. (%)	Reca II (%)	F1-Score (%)
I	58,90	98,53	73,73	96,67	99,61	98,12	83,52	98,84	90,54	98,23	100,00	99,11	64,11	98,16	77,56	98,16	100,00	99,07
II	67,21	99,92	80,37	98,76	99,92	99,34	65,02	100,00	78,80	98,38	100,00	99,18	79,27	99,61	88,28	98,69	99,84	99,26
III	66,55	99,69	79,81	97,18	100,00	98,57	63,88	99,84	77,91	97,26	99,84	98,53	59,29	99,07	74,18	97,85	99,84	98,84
aVR	65,05	99,69	78,73	98,69	92,47	95,48	67,49	99,38	80,39	98,61	93,01	95,73	77,63	99,53	87,23	98,61	93,14	95,80
aVL	40,36	99,30	57,39	96,52	95,30	95,91	61,66	98,76	75,92	94,17	96,09	95,12	47,45	98,92	64,14	95,30	95,94	95,62
aVF	73,52	100,00	84,74	98,08	99,92	98,99	74,77	100,00	85,56	98,23	100,00	99,11	60,04	99,53	74,90	98,23	99,92	99,07
V1	72,97	99,45	84,18	98,92	94,52	96,67	65,99	99,45	79,34	98,76	94,80	96,74	65,72	99,15	79,05	98,84	95,51	97,15
V2	69,93	97,11	81,31	98,84	93,90	96,30	66,58	96,60	78,83	98,84	93,48	96,09	70,24	98,53	82,02	98,61	93,35	95,91
V3	61,28	97,78	75,34	98,38	96,45	97,41	67,93	99,07	80,59	98,38	95,01	96,67	62,35	96,60	75,79	98,61	97,11	97,85
V4	66,48	99,77	79,79	98,00	99,77	98,88	66,13	99,69	79,51	98,00	99,77	98,88	76,74	99,22	86,55	98,31	99,92	99,11
V5	80,98	99,92	89,46	98,46	99,92	99,18	80,98	100,08	89,52	98,46	99,92	99,18	60,35	100,00	75,27	98,53	99,92	99,22

<b>V6</b>	70,9 8	99,8 4	82,98	99,1 5	99,9 2	99,53	81,2 3	99,7 7	89,55	98,6 1	100, 00	99,30	62,6 9	99,5 3	76,93	98,8 4	100, 00	99,42
<b>Média</b>	66,1 8	99,25	78,99	98,1 4	97,64	97,87	70,4 3	99,29	82,21	97,9 9	97,66	97,80	65,4 9	98,99	78,49	98,2 2	97,87	98,03



Tabela 5 - Diferenças percentuais entre as métricas do experimento com aumento de dados relacionando antes e após a etapa de pós-processamento.

Derivação	CNN1			CNN2			CNN3		
	Diferenças percentuais			Diferenças percentuais			Diferenças percentuais		
	Prec. (%)	Recall (%)	F1-Score (%)	Prec. (%)	Recall (%)	F1-Score (%)	Prec. (%)	Recall (%)	F1-Score (%)
I	37,77	1,08	24,39	14,71	1,16	8,57	34,05	1,84	21,51
II	31,55	0,00	18,97	33,36	0,00	20,38	19,42	0,23	10,98
III	30,63	0,31	18,76	33,38	0,00	20,62	38,56	0,77	24,66
aVR	33,64	-7,22	16,75	31,12	-6,37	15,34	20,98	-6,39	8,57
aVL	56,16	-4,00	38,52	32,51	-2,67	19,20	47,85	-2,98	31,48
aVF	24,56	-0,08	14,25	23,46	0,00	13,55	38,19	0,39	24,17
V1	25,95	-4,93	12,49	32,77	-4,65	17,40	33,12	-3,64	18,10
V2	28,91	-3,21	14,99	32,26	-3,12	17,26	28,37	-5,18	13,89
V3	37,10	-1,33	22,07	30,45	-4,06	16,08	36,26	0,51	22,06
V4	31,52	0,00	19,09	31,87	0,08	19,37	21,57	0,70	12,56
V5	17,48	0,00	9,72	17,48	-0,16	9,66	38,18	-0,08	23,95
V6	28,17	0,08	16,55	17,38	0,23	9,75	36,15	0,47	22,49
Média	<b>31,95</b>	<b>-1,61</b>	<b>18,88</b>	<b>27,56</b>	<b>-1,63</b>	<b>15,60</b>	<b>32,73</b>	<b>-1,11</b>	<b>19,54</b>

Tabela 6 - Comparativo entre as arquiteturas com melhor desempenho considerando a aplicação de aumento de dados no trabalho atual com o experimento base proposto por Silva, (2023).

Derivação	Melhor Resultado Sem Aumento de Dados (CNN2)						Melhor Resultado Com Aumento de Dados (CNN3)					
	Antes do Pós-Processamento			Depois do Pós-Processamento			Antes do Pós-Processamento			Depois do Pós-Processamento		
	Prec. (%)	Recall (%)	F1-Score (%)	Prec. (%)	Recall (%)	F1-Score (%)	Prec. (%)	Recall (%)	F1-Score (%)	Prec. (%)	Recall (%)	F1-Score (%)
I	75,03	99,79	85,66	99,95	99,79	99,87	64,11	98,16	77,56	98,16	100,00	99,07
II	71,30	100,00	83,25	100,00	100,00	100,00	79,27	99,61	88,28	98,69	99,84	99,26
III	71,38	100,00	83,3	100,00	100,00	100,00	59,29	99,07	74,18	97,85	99,84	98,84
aVR	83,13	100,00	90,79	99,94	100,00	99,97	77,63	99,53	87,23	98,61	93,14	95,80
aVL	72,24	99,22	83,61	99,95	99,22	99,59	47,45	98,92	64,14	95,30	95,94	95,62
aVF	79,52	100,00	88,59	100,00	100,00	100,00	60,04	99,53	74,90	98,23	99,92	99,07
V1	76,50	100,00	86,69	100,00	100,00	100,00	65,72	99,15	79,05	98,84	95,51	97,15
V2	78,77	99,83	88,06	100,00	99,83	99,91	70,24	98,53	82,02	98,61	93,35	95,91
V3	72,67	100,00	84,17	99,95	100,00	99,98	62,35	96,60	75,79	98,61	97,11	97,85
V4	69,96	99,96	82,31	99,96	99,96	99,96	76,74	99,2	86,55	98,31	99,9	99,11

								2			2	
<b>V5</b>	75,90	100,0 0	86,3	100,00	100,0 0	100,00	60,35	100,00	75,27	98,53	99,9 2	99,22
<b>V6</b>	90,90	100,0 0	95,23	100,00	100,0 0	100,00	62,69	99,5 3	76,93	98,84	100,00	99,42
<b>Média</b>	<b>76,44</b>	<b>99,9 0</b>	<b>86,50</b>	<b>99,98</b>	<b>99,9 0</b>	<b>99,94</b>	<b>65,49</b>	<b>98,99</b>	<b>78,49</b>	<b>98,22</b>	<b>97,87</b>	<b>98,03</b>

## 6 CONCLUSÕES

Este trabalho da disciplina de Projeto Final de Curso (FTL056) do curso de Engenharia Elétrica – Telecomunicações da Universidade Federal do Amazonas trouxe contribuições para a área de detecção do complexo QRS em um eletrocardiograma de 12 derivações, utilizando um projeto correlato como base, e acrescentando técnicas importantes e utilizadas em contexto de projetos que envolvem o uso de conjunto de dados e Aprendizado de Máquina.

O processo desenvolvido neste trabalho permitiu o contato com vários conteúdos relacionados à pesquisa de Aprendizado de Máquina, como a base de dados *St. Petersburg INCART 12-Lead*, utilizada em vários trabalhos de pesquisa relacionados a eletrocardiograma, não apenas aqueles relacionados ao tema desenvolvido, mas como também outras aplicações em Processamento Digital de Sinais. Desde as atividades de pré-processamento dos sinais que se encontram em um domínio, como no processo de transformação para imagens.

Primeiramente, é importante salientar que o texto por Silva (2023) é relevante e suficientemente detalhado ao ponto de que foi possível propor uma técnica de aumento de dados a partir das informações tratadas no trabalho, e de que também foi possível reproduzir todas as etapas descritas pelo autor em sua publicação.

Houve um desafio técnico em refletir a consideração de que os fenômenos físicos que ocorrem nas 12 derivações de um eletrocardiograma, e desencadeiam as formas de onda básicas visualizadas no eletrocardiógrafo são síncronas no domínio do tempo. Isso acarretou a necessidade do desenvolvimento de códigos de programação que realizassem a sincronização do que foi processado para uma derivação em todo o corpo do sinal para as demais derivações, respeitando o princípio de que os fenômenos bioelétricos representados pelas ondas do eletrocardiograma ocorrem de forma síncrona ao longo das 12 derivações. Tais operações foram usadas para sincronizar as estruturas de dados resultantes dos sinais anotados com as amostras de fato, dado que o *software SignalLabeler* armazena ambas as informações em estruturas de dados separadas entre si. Para se prosseguir com os processos de geração do Padrão-Ouro do método proposto por Silva (2023), foi necessário refinar repetidas vezes uma ferramenta de sincronização de dados.

Informações imprescindíveis para guiar o processo de localização das anomalias ao longo dos registros da base de dados *St. Petersburg 12-Lead* surgiram apenas através da exploração analítica dos metadados dos arquivos ATR fornecidos pelo repositório fonte, uma vez que tal informação não está explícita na documentação. Essa descoberta foi responsável pela realização da etapa descrita no item 4.2.1 Algoritmo de marcação das anomalias, uma vez que se percebeu as marcações V, N e J presentes no conteúdo dos dados, e ao se plotar em confronto com as amostras, concluiu-se que se tratava de marcadores de anomalias ao longo dos registros. Esse processo permitiu a redução do espaço de busca das anomalias, evitando que se fizesse amostras repetidas que já existiam no grupo Padrão-Ouro fornecido por Silva (2023).

O conceito de padrão-ouro (*Ground Truth*) e a obtenção deste foi fundamental na condução deste estudo, uma vez que o conjunto de dados gerado para servir como referência no processo de treinamento reflete a qualidade e a precisão almejadas na análise realizada. O acompanhamento da orientadora e supervisor do trabalho foi de extrema importância, pois seus conhecimentos transmitidos foram essenciais para garantir a assertividade na condução da atividade. A partir desses elementos, foi possível não apenas compreender a complexidade do tema abordado, mas também desenvolver uma abordagem metodológica consistente e eficiente.

## **6.1 Trabalhos Futuros**

O trabalho realizado tem o potencial de contribuir no tema de pesquisa do grupo de Pesquisa em Reconhecimento de Padrões e Otimização da qual minha orientadora participa, qual seja, a aplicação de Aprendizado de Máquina para a obtenção automática do Escore de Selvester.

## Referências Bibliográficas

AGGARWAL, C. C. **Neural Networks and Deep Learning**. Cham: Springer International Publishing, 2018.

BENGIO, Y.; LECUN, Y. Convolutional Networks for Images, Speech, and Time-Series. fev. 1997.

GOLDBERGER, A. et al. St Peterburg INCART 12-lead Arrhythmia Database. **PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals.**, p. e215–e220, 2000a.

GOLDBERGER, A. L. et al. PhysioBank, PhysioToolkit, and PhysioNet. **Circulation**, v. 101, n. 23, 13 jun. 2000b.

GOLDBERGER, A. L.; GOLDBERGER, Z. D.; SHVILKIN, A. **Goldberger's Clinical Electrocardiography**. Ninth ed. Philadelphia, PA: Elsevier, 2018.

GONZALEZ, R. C.; WOODS, R. E. **Digital Image Processing (3rd Edition)**. USA: Prentice-Hall, Inc., 2006.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [s.l.] MIT Press, 2016.

LORING, Z. et al. A detailed guide for quantification of myocardial scar with the Selvester QRS score in the presence of electrocardiogram confounders. **Journal of electrocardiology**, v. 44, n. 5, p. 544–54, 2011.

MINISTÉRIO DA SAÚDE. **Doenças cardiovasculares: principal causa de morte no mundo pode ser prevenida**.

PAULA DA SILVA, M. DE. **Deteção do Complexo QRS em Eletrocardiogramas com 12 derivações utilizando redes neurais convolucionais**. Dissertação de Mestrado —Manaus: Universidade Federal do Amazonas, 2023.

SAINI, S. K.; GUPTA, R. Artificial intelligence methods for analysis of electrocardiogram signals for cardiac abnormalities: state-of-the-art and future challenges. **Artificial Intelligence Review**, v. 55, n. 2, p. 1519–1565, 23 fev. 2022.

WORLD HEALTH ORGANIZATION. **Cardiovascular Diseases**. Disponível em: <[https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))>. Acesso em: 12 mar. 2024.